

TRƯỜNG ĐẠI HỌC — KHOA CÔNG NGHỆ THÔNG TIN

Học phần: Trí tuệ nhân tạo / Deep Learning

ĐẠO HÀM & KHỞI TẠO TRONG DEEP LEARNING:

BACKPROPAGATION VÀ PARAMETER INITIALIZATION

*Derivatives & Initialization in Deep Learning: Backpropagation and Parameter
Initialization*

Nhóm thực hiện: Nhóm sinh viên Deep Learning
Giảng viên hướng dẫn: (điền tên giảng viên)

Tháng 9, 2026

Mục lục

1	Giới thiệu	5
	Bối cảnh lịch sử	5
2	Nền tảng toán học	6
2.1	Đạo hàm (Derivative)	6
2.2	Đạo hàm riêng (Partial Derivative)	7
2.3	Gradient	7
2.4	Jacobian — khi đầu ra không chỉ là một số	7
2.5	Quy tắc chuỗi (Chain Rule)	8
2.6	Đồ thị tính toán (Computational Graph)	8
2.7	Đồ thị có nhánh: khi một biến được dùng nhiều lần	9
3	Lan truyền tiến (Forward Propagation)	10
3.1	Softmax và Cross-Entropy: từ logits tới xác suất	10
4	Lan truyền ngược (Backpropagation)	11
4.1	Trực giác (Intuition)	11
4.2	Scalar Derivation — ví dụ từ neuron đơn tới mạng 2 lớp	12
4.3	Matrix Form (batch, khớp code NumPy/PyTorch)	13
4.4	Độ phức tạp tính toán (Computational Complexity)	14
4.5	Backpropagation vs. Gradient Descent	15
4.6	Các biến thể Gradient Descent (SGD, Momentum, Adam)	16
5	Khởi tạo tham số (Parameter Initialization)	16
5.1	Vì sao Initialization quan trọng	16
5.2	Zero Initialization	17
5.3	Random Initialization	17
5.4	Trực giác fan_in, fan_out, $\text{Var}(W)$	18
5.5	LeCun, Xavier/Glorot, He/Kaiming Initialization	18
5.6	Chuỗi ảnh hưởng: Initialization $\rightarrow$ Training Stability	19
5.7	Ví dụ số: lan truyền variance qua nhiều lớp	19
5.8	Activation $\times$ Initialization: bảng tương thích	20
6	Vanishing và Exploding Gradient	20
6.1	Thực nghiệm bổ sung: độ sâu ảnh hưởng thế nào tới initialization	21
7	Phương pháp thực nghiệm	22
7.1	Dataset và tiền xử lý	22
7.2	Kiến trúc mô hình	24
7.3	Thiết kế lưới thực nghiệm	24

7.4	Metric thu thập	25
8	Hiện thực	25
8.1	Part A: Manual Backpropagation	25
8.2	Part B: PyTorch Autograd	25
8.3	Kiểm tra tính đúng đắn: Gradient Checking	27
9	Kết quả thực nghiệm	27
9.1	Bức tranh tổng thể: test accuracy	27
9.2	Gradient norm theo layer (Experiment 7)	29
9.3	Activation variance theo layer	30
9.4	Weight variance theo layer	30
9.5	Loss và Accuracy theo epoch (Experiment 8)	31
9.6	Phân phối gradient và activation (histogram)	32
9.7	Toàn cảnh: loss theo epoch của cả 20 cấu hình	32
10	Thảo luận	33
10.1	Vì sao Sigmoid thất bại ngay cả với He/Xavier?	33
10.2	Đối chiếu dự đoán lý thuyết với số liệu	34
10.3	Liên hệ tới kiến trúc hiện đại	34
10.4	Câu hỏi thường gặp	35
11	Hạn chế	35
12	Kết luận	36
	Tài liệu tham khảo	36
A	Mã nguồn Manual Backpropagation	37
B	Bảng kết quả đầy đủ (20 cấu hình)	38
C	20 câu hỏi phản biện thường gặp	39
D	Danh mục notebook	41
E	Bảng thuật ngữ Việt–Anh	42

Danh mục hình

1	Đạo hàm = độ dốc của tiếp tuyến = độ nhảy cục bộ của y theo x	6
2	Computational graph của $z = wx + b \rightarrow a = \text{ReLU}(z) \rightarrow L = \frac{1}{2}(a - y)^2$. Mũi tên xanh (liền) = forward; mũi tên đỏ (đứt) = backward, đi ngược đúng theo các cạnh forward.	9
3	Gradient đi ngược Loss $\rightarrow$ Output $\rightarrow$ Hidden $\rightarrow$ Input. Mỗi $\delta_l = \partial L / \partial z_l$ được tính một lần rồi dùng lại cho mọi tham số của lớp l — đây là điểm làm Backprop hiệu quả (Mục 4.4).	12
4	Phân phối 10 000 giá trị W mô phỏng ngay sau khởi tạo theo từng scheme (lớp 128×128 , khớp $n_{\text{in}}=n_{\text{out}}=128$ của kiến trúc thực nghiệm Mục 7) — Zero co về một điểm; độ rộng phân phối tăng dần Random $<$ LeCun = Xavier (khi $n_{\text{in}}=n_{\text{out}}$) $<$ He, đúng thứ tự $\text{Var}(W)$ ở Bảng 5.	18
5	Gradient RMS lớp 1 tại khởi tạo (trái) và test accuracy sau 8 epoch (phải), theo độ sâu mạng, activation ReLU. Đường chấm ở đồ thị phải = mức ngẫu nhiên (10%).	21
6	Mẫu ảnh thật của cả 10 lớp Fashion-MNIST (8 mẫu/lớp, lấy ngẫu nhiên từ tập train đang dùng).	23
7	Test accuracy, toàn bộ lưới 5×4 (đường chấm = mức ngẫu nhiên 10%).	28
8	RMS gradient mỗi trọng số theo layer, bước đầu tiên, activation Sigmoid (thang log). Đường “Zero” không hiện được vì gradient đúng bằng 0 tại 6 lớp ẩn (Mục 5.2) — log của 0 không xác định.	29
9	Phương sai activation theo layer, bước đầu tiên, activation Sigmoid (thang log).	30
10	Phương sai trọng số theo layer (đo thực tế ngay sau khởi tạo, activation ReLU).	30
11	Loss (trái) và validation accuracy (phải) theo epoch, activation ReLU. Zero/Random nằm sát mức ngẫu nhiên (đường chấm) suốt 15 epoch.	31
12	Phân phối gradient tại lớp giữa mạng (lớp 3), activation Sigmoid, 5 scheme.	32
13	Phân phối activation tại lớp giữa mạng (lớp 3), activation Sigmoid, 5 scheme.	32
14	Loss theo epoch, toàn bộ 20 cấu hình (hàng = scheme, cột = activation; nét liền = train, nét đứt = validation; trục tung cắt ở 2,5 để các đường hội tụ không bị nén). Hai hàng Zero/Random phẳng tuyệt đối ở mọi cột — xác nhận trực quan Bảng 13 không có ngoại lệ ẩn nào ngoài lát cắt đã trình bày.	33

Danh mục bảng

1	Forward và backward cho ví dụ số Mục 2.6	9
2	Forward/backward mạng 2 lớp — khớp PyTorch autograd (sai số = 0) và finite-difference (sai số $< 10^{-9}$)	13
3	Phân biệt Backpropagation và Gradient Descent	15
4	Truy vết 2 bước Gradient Descent với Zero-init — $W^{(1)}, W^{(2)}$ đúng yên tuyệt đối	17

5	Các scheme initialization dùng trong báo cáo (và trong lưới thực nghiệm Mục 9)	18
6	$\text{Var}(a^{(l)})$ lý thuyết theo độ sâu l , ba scheme minh hoạ ($n_{\text{in}} = 128$)	19
7	Khuyến nghị lý thuyết Activation $\times$ Initialization (không phải quy tắc tuyệt đối)	20
8	Minh hoạ số: hệ số nhân dồn g^L theo độ sâu L (đã tính lại bằng <code>experiments/toy_example_verify.py</code>)	20
9	10 lớp của Fashion-MNIST	23
10	Lưới thực nghiệm $5 \times 4 = 20$ cấu hình (Experiment 1–8 đều rút ra từ lưới này)	24
11	Siêu tham số cố định cho toàn bộ 20 cấu hình	24
12	Kết quả Gradient Checking (mạng $6 \rightarrow 8 \rightarrow 5 \rightarrow 1$, activation Tanh) . . .	27
13	Test accuracy sau 15 epoch, toàn bộ 20 cấu hình	27
14	Kết quả đầy đủ: train/val/test loss và test accuracy, 20 cấu hình	39
15	Đối chiếu thuật ngữ tiếng Việt – tiếng Anh dùng trong báo cáo	42

1 Giới thiệu

Huấn luyện một mạng nơ-ron về bản chất là giải một bài toán tối ưu: tìm bộ tham số θ (các ma trận trọng số W và vector bias b) sao cho hàm mất mát $L(\theta)$ nhỏ nhất có thể. Để giải bài toán này bằng Gradient Descent, có hai câu hỏi bắt buộc phải trả lời trước khi nói đến việc “huấn luyện”:

1. **Tính gradient thế nào?** Một mạng thực tế có thể có hàng triệu tham số; tính $\partial L / \partial \theta_i$ cho từng tham số một cách ngây thơ (ví dụ bằng finite-difference) là không khả thi. Đây là vấn đề mà **Backpropagation** giải quyết.
2. **Bắt đầu từ đâu?** Gradient Descent chỉ di chuyển tham số theo hướng giảm loss *cục bộ*, xuất phát từ giá trị khởi tạo θ_0 . Chọn θ_0 sai có thể khiến mạng không bao giờ học được gì, bất kể thuật toán tối ưu tốt đến đâu. Đây là vấn đề của **Parameter Initialization**.

Báo cáo này đi từ nền tảng toán học (đạo hàm, chain rule, computational graph) tới hai chủ đề trên, xen kẽ trực giác trước rồi mới tới công thức và ví dụ số, tránh trình bày Backpropagation như một “thuật toán thần kỳ” tách rời khỏi Giải tích. Phần thực nghiệm (Mục 7–9) kiểm chứng lại các kết luận lý thuyết bằng số liệu thật trên Fashion-MNIST, không dùng số liệu minh họa giả định.

Sơ đồ tư duy của cả báo cáo. Chain Rule $\rightarrow$ Computational Graph $\rightarrow$ đạo hàm cục bộ từng bước $\rightarrow$ Backpropagation (thuật toán *tính gradient* hiệu quả) $\rightarrow$ Gradient Descent/Optimizer (*dùng gradient* đó để cập nhật tham số) — và song song: Initialization quyết định gradient có “chảy” được qua mạng sâu hay không (Mục 6), nên hai chủ đề của báo cáo thực chất là hai mặt của cùng một câu hỏi: *làm sao tín hiệu học (gradient) đi xuyên suốt một mạng nhiều lớp mà không biến mất hay bùng nổ?*

Bối cảnh: vì sao hai chủ đề này lại tách biệt thành hai bước phát triển lịch sử

Hai chủ đề của báo cáo không xuất hiện cùng lúc trong lịch sử Deep Learning — Backpropagation được giải quyết trước, Initialization được nhận ra là vấn đề riêng biệt *sau*, khi các mạng ngày càng sâu hơn:

- **1986:** Rumelhart et al. [1986] phổ biến rộng rãi Backpropagation như một phương pháp thực tế để huấn luyện mạng nhiều lớp (*multilayer perceptron*), dựa trên Chain Rule — giải quyết *câu hỏi 1* (tính gradient hiệu quả).
- **Cuối thập niên 1990:** khi các mạng bắt đầu sâu hơn, LeCun et al. [2012] tổng hợp nhiều kinh nghiệm thực hành (*Efficient BackProp*), trong đó có khuyến nghị khởi tạo trọng số theo $1/\sqrt{n_{\text{in}}}$ — mầm mống sớm của *câu hỏi 2* (chọn điểm xuất phát), nhưng chưa có phân tích variance đầy đủ.
- **2010:** Glorot and Bengio [2010] đưa ra phân tích variance có hệ thống đầu tiên (Xavier/Glorot initialization, cân bằng cả forward lẫn backward), giải thích rõ *tại sao* initialization sai làm mạng sâu khó huấn luyện — đúng bằng phân tích Mục 6 của báo cáo này.
- **2015:** khi ReLU trở thành activation phổ biến nhất (thay Sigmoid/Tanh), He et al. [2015] nhận ra công thức Xavier không tối ưu cho ReLU (do ReLU không đối xứng

quanh 0) và đề xuất hiệu chỉnh —He/Kaiming initialization — cho phép huấn luyện các mạng sâu hơn đáng kể so với trước đó.

Ba mươi năm phát triển này chính là lý do báo cáo trình bày Initialization như một chủ đề *riêng*, không gộp chung vào Backpropagation dù cả hai đều xoay quanh cùng một câu hỏi cốt lõi về gradient.

2 Nền tảng toán học


Các khái niệm trong mục này là kiến thức Giải tích/Đại số tuyến tính chuẩn, trình bày lại theo hướng ứng dụng cho Deep Learning (tham khảo cách trình bày tổng quát trong Bishop [2006] và Goodfellow et al. [2016]).

2.1 Đạo hàm (Derivative)

Cách hiểu đơn giản. Đạo hàm trả lời câu hỏi: *nếu nhích x một chút, $y = f(x)$ đổi bao nhiêu?* — nó đo **độ nhạy** của đầu ra theo đầu vào tại một điểm.

$$\frac{dy}{dx} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}.$$

Ví dụ $y = x^2$: $dy/dx = 2x$. Tại $x = 1,5$, đạo hàm = 3, nghĩa là quanh $x = 1,5$, nhích x thêm một lượng nhỏ h thì y đổi xấp xỉ $3h$ (Hình 1 minh hoạ bằng tiếp tuyến).



Hình 1: Đạo hàm = độ dốc của tiếp tuyến = độ nhạy cục bộ của y theo x .

Vai trò trong Deep Learning. “ x ” ở đây chính là một tham số (w hay b) và “ y ” là hàm mất mát L . Đạo hàm $\partial L / \partial w$ cho biết: *nếu tăng w một chút, loss tăng hay giảm, nhanh cỡ nào?* — đây chính là “tín hiệu học” mà Gradient Descent dùng để sửa tham số. Không có đạo hàm, mạng không biết nên chỉnh w theo hướng nào.

2.2 Đạo hàm riêng (Partial Derivative)

Khi L phụ thuộc nhiều biến cùng lúc ($L(w_1, w_2, \dots, w_n)$ — một mạng thực tế có thể có hàng triệu w_i), đạo hàm riêng $\partial L / \partial w_i$ giữ *mọi biến khác cố định*, chỉ đo độ nhạy của L theo riêng w_i . Về công thức, tính giống hệt đạo hàm thường, chỉ khác ở chỗ ta “đóng băng” các biến còn lại khi lấy vi phân.

2.3 Gradient

Cách hiểu đơn giản. Gradient gộp toàn bộ đạo hàm riêng thành một vector — giống như gộp “độ dốc theo từng hướng riêng lẻ” thành một mũi tên chỉ hướng dốc nhất.

$$\nabla_{\theta} L = \left(\frac{\partial L}{\partial \theta_1}, \frac{\partial L}{\partial \theta_2}, \dots, \frac{\partial L}{\partial \theta_n} \right).$$

$\nabla_{\theta} L$ là hướng làm L tăng nhanh nhất tại điểm hiện tại θ ; do đó $-\nabla_{\theta} L$ là hướng làm L giảm nhanh nhất cục bộ — đây là nền tảng của Gradient Descent (Mục 4.5). Lưu ý: gradient tự nó chỉ là một *phép đo* (một vector), chưa phải là một thuật toán cập nhật tham số.

Vì sao chính xác là hướng dốc nhất? Với một hướng đơn vị bất kỳ v ($\|v\| = 1$), **đạo hàm theo hướng** (*directional derivative*) đo tốc độ đổi của L khi di chuyển theo v :

$$D_v L = \nabla_{\theta} L \cdot v = \|\nabla_{\theta} L\| \|v\| \cos \varphi = \|\nabla_{\theta} L\| \cos \varphi$$

(φ = góc giữa $\nabla_{\theta} L$ và v). Biểu thức này lớn nhất khi $\cos \varphi = 1$, tức v cùng hướng với $\nabla_{\theta} L$ ($\varphi = 0$) — chứng minh trực tiếp gradient là hướng tăng nhanh nhất; tương tự, $D_v L$ nhỏ nhất (âm nhiều nhất) khi v ngược hướng gradient ($\varphi = 180^\circ$), tức hướng giảm nhanh nhất là $-\nabla_{\theta} L$.

Ví dụ số ($L(\theta_1, \theta_2) = \theta_1^2 + 2\theta_2^2$ tại $\theta = (1, 1)$): $\nabla L = (2\theta_1, 4\theta_2) = (2, 4)$, $\|\nabla L\| = \sqrt{20} \approx 4,47$. So sánh $D_v L$ theo 3 hướng đơn vị khác nhau:

- $v = \nabla L / \|\nabla L\| \approx (0,447; 0,894)$ (cùng hướng gradient): $D_v L = \sqrt{20} \approx 4,47$ (lớn nhất).
- $v = (1, 0)$ (chỉ đổi θ_1): $D_v L = (2, 4) \cdot (1, 0) = 2$.
- $v = -\nabla L / \|\nabla L\| \approx (-0,447; -0,894)$ (ngược hướng gradient): $D_v L = -\sqrt{20} \approx -4,47$ (nhỏ nhất — giảm nhanh nhất).

Đúng như dự đoán: đi theo $-\nabla L$ cho tốc độ giảm L nhanh hơn hẳn đi theo $(1, 0)$ hay bất kỳ hướng nào khác — đây chính xác là lý do Gradient Descent (Mục 4.5) chọn hướng cập nhật $-\nabla_{\theta} L$ chứ không phải hướng nào khác.

2.4 Jacobian — khi đầu ra không chỉ là một số

Gradient $\nabla_{\theta} L$ ở trên chỉ áp dụng khi đầu ra là *một số* (loss L luôn là một số). Nhưng bên trong mạng, nhiều phép biến đổi có đầu ra là *cả một vector* — ví dụ $z = Wx + b$ với $x \in \mathbb{R}^n, z \in \mathbb{R}^m$. Khi đó “đạo hàm” tổng quát thành một **ma trận Jacobian**: mỗi hàng

là gradient của một toạ độ đầu ra theo toàn bộ đầu vào.

$$J = \frac{\partial z}{\partial x} = \begin{pmatrix} \frac{\partial z_1}{\partial x_1} & \cdots & \frac{\partial z_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial z_m}{\partial x_1} & \cdots & \frac{\partial z_m}{\partial x_n} \end{pmatrix} \in \mathbb{R}^{m \times n}.$$

Cách hiểu đơn giản. Gradient là “1 số $\rightarrow$ nhiều số” (một hàng của Jacobian). Jacobian là “nhiều số $\rightarrow$ nhiều số” (toàn bộ ma trận). Backpropagation về bản chất là nhân liên tiếp các Jacobian của từng phép biến đổi (*Jacobian-vector product*) — không bao giờ cần lập ra Jacobian đầy đủ (rất tốn bộ nhớ với mạng lớn), chỉ cần nhân nó với một vector, xem Mục 4.3.

Ví dụ: với $z = Wx + b$ ($W \in \mathbb{R}^{m \times n}$), Jacobian của z theo x chính là W : $\partial z / \partial x = W$. Với hàm kích hoạt $a = f(z)$ áp dụng *độc lập theo từng toạ độ* (mọi activation trong Mục 5.5 đều vậy), Jacobian của nó là một **ma trận đường chéo** $\text{diag}(f'(z_1), \dots, f'(z_m))$ — đây chính là lý do phép “nhân Jacobian-vector” của một activation rút gọn thành phép nhân từng phần tử $\odot$ dùng xuyên suốt Mục 4.2–4.3, thay vì một phép nhân ma trận đầy đủ.

2.5 Quy tắc chuỗi (Chain Rule)

$$y = f(g(x)) \implies \frac{dy}{dx} = \frac{dy}{dg} \cdot \frac{dg}{dx}.$$

Cách hiểu đơn giản. g biến đổi x thành một đại lượng trung gian; f biến đổi đại lượng đó thành y . Độ nhạy tổng của y theo x = độ nhạy của y theo đại lượng trung gian, nhân với độ nhạy của đại lượng trung gian theo x — “truyền độ nhạy” qua từng bước trung gian, giống truyền tin đồn qua một chuỗi người: mức độ “sai lệch” tới người cuối phụ thuộc vào mức khuếch đại/suy giảm ở *mỗi* khâu trung gian.

Một neuron đơn là một chuỗi biến đổi lồng nhau:

$$x \xrightarrow{z=wx+b} z \xrightarrow{a=\sigma(z)} a \xrightarrow{L=\text{loss}(a,y)} L.$$

Áp dụng Chain Rule liên tiếp cho từng tham số:


$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w}, \quad \frac{\partial L}{\partial b} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial b}, \quad \frac{\partial L}{\partial x} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial x}.$$

$\partial L / \partial w$ và $\partial L / \partial b$ dùng để **cập nhật tham số của chính lớp này**; $\partial L / \partial x$ dùng để **tiếp tục lan truyền ngược sang lớp phía trước** (vì x chính là đầu ra của lớp trước đó) — đây là hạt giống của thuật toán Backpropagation ở Mục 4.

2.6 Đồ thị tính toán (Computational Graph)

Một biểu thức toán phức tạp có thể vẽ thành một đồ thị có hướng: mỗi nút là một phép toán cơ bản (cộng, nhân, hàm kích hoạt...), mỗi cạnh mang một giá trị trung gian. **Forward pass** đi từ trái sang phải, tính từng giá trị; **backward pass** đi ngược lại, và

tại *mỗi* nút chỉ cần biết đạo hàm cục bộ của riêng phép toán đó, rồi nhân dồn theo Chain Rule. Đây là lý do Backpropagation không cần suy ra một công thức đóng (closed-form) cho toàn mạng — chỉ cần mỗi phép toán “biết” đạo hàm của chính nó, và một cơ chế nhân dồn có hệ thống.



Hình 2: Computational graph của $z = wx + b \rightarrow a = \text{ReLU}(z) \rightarrow L = \frac{1}{2}(a - y)^2$. Mũi tên xanh (liền) = forward; mũi tên đỏ (đứt) = backward, đi ngược đúng theo các cạnh forward.

Đạo hàm cục bộ của từng nút trong Hình 2:

$$\frac{\partial L}{\partial a} = a - y, \quad \frac{\partial a}{\partial z} = \text{ReLU}'(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}, \quad \frac{\partial z}{\partial w} = x, \quad \frac{\partial z}{\partial b} = 1, \quad \frac{\partial z}{\partial x} = w.$$

Ví dụ số ($x = 2$, $w = 0,5$, $b = -0,3$, $y = 1$, đã kiểm chứng bằng NumPy, PyTorch autograd và finite-difference trong `experiments/toy_example_verify.py` — ba cách tính cho kết quả khớp tuyệt đối):

Bảng 1: Forward và backward cho ví dụ số Mục 2.6

Forward	Giá trị	Backward	Giá trị
$z = wx + b$	0,7000	$\partial L / \partial a = a - y$	-0,3000
$a = \text{ReLU}(z)$	0,7000	$\partial a / \partial z$ ($z > 0$)	1,0000
$L = \frac{1}{2}(a - y)^2$	0,0450	$\partial L / \partial z$	-0,3000
		$\partial L / \partial w = (\partial L / \partial z) x$	-0,6000
		$\partial L / \partial b$	-0,3000
		$\partial L / \partial x = (\partial L / \partial z) w$	-0,1500

2.7 Đồ thị có nhánh: khi một biến được dùng nhiều lần

Ví dụ Mục 2.6 là một **chuỗi thẳng** — mỗi biến chỉ dùng đúng một lần. Nhưng trong mạng thật, một tham số (vd. w) thường ảnh hưởng tới L qua *nhiều đường đi khác nhau* — ví dụ trọng số dùng chung (*weight sharing*) trong CNN (cùng một bộ lọc quét qua nhiều vị trí ảnh) hay trong RNN (cùng một W dùng lại ở mọi bước thời gian). Quy tắc chuỗi tổng quát cho trường hợp này (**multivariable chain rule**): nếu x ảnh hưởng L qua hai đường p và q , gradient **cộng dồn theo mọi đường đi**:

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial p} \cdot \frac{\partial p}{\partial x} + \frac{\partial L}{\partial q} \cdot \frac{\partial q}{\partial x}.$$

Cách hiểu đơn giản. Nếu một khoản đầu tư ảnh hưởng tới lợi nhuận qua *hai* kênh khác nhau, tổng ảnh hưởng lên lợi nhuận là *cộng* tác động của từng kênh lại — không phải chọn kênh này hay kênh kia. Gradient qua nhiều đường đi hoạt động y hệt vậy: **không đường nào “che” đường nào**, tất cả cộng dồn.

Ví dụ số: w dùng chung cho hai input $x_1 = 2$, $x_2 = 3$: $z = wx_1 + wx_2$, $a = z$, $L = \frac{1}{2}(a - y)^2$, với $w = 0,4$, $y = 1$.

$$z = 0,4 \times 2 + 0,4 \times 3 = 2,0, \quad a = 2,0, \quad L = \frac{1}{2}(2,0 - 1)^2 = 0,5.$$

Xem w ảnh hưởng L qua *hai nhánh* $p = wx_1$ và $q = wx_2$ ($\partial L / \partial p = \partial L / \partial q = a - y$, $\partial p / \partial w = x_1$, $\partial q / \partial w = x_2$):

$$\begin{aligned} \frac{\partial L}{\partial w} &= \frac{\partial L}{\partial p} \frac{\partial p}{\partial w} + \frac{\partial L}{\partial q} \frac{\partial q}{\partial w} \\ &= (a - y)(x_1 + x_2) = 1,0 \times 5 = 5,0. \end{aligned}$$

Kiểm tra trực tiếp bằng đạo hàm thường trên $L(w) = \frac{1}{2}(w(x_1+x_2) - y)^2$: $dL/dw = (w(x_1+x_2) - y)(x_1+x_2) = (2,0 - 1) \times 5 = 5,0$ — khớp tuyệt đối (kiểm chứng bằng NumPy/autograd trong hàm `example_shared_weight`, `experiments/toy_example_verify.py`).

Vì sao quan trọng cho Backpropagation: khi lan truyền ngược qua computational graph, **mỗi khi một nút có nhiều mũi tên forward đi RA** (*fan-out* — nút đó được dùng làm input cho nhiều phép toán khác), gradient lan truyền ngược **VỀ** nút đó phải **cộng dồn** từ mọi nhánh. Đây là quy tắc tổng quát mà mọi framework autograd (kể cả PyTorch) thực hiện ngầm; `src/manual_nn.py` (Mục 8) không cần xử lý minh tường vì kiến trúc MLP trong báo cáo không có weight-sharing, nhưng nguyên lý này là nền tảng bắt buộc phải hiểu trước khi mở rộng sang CNN/RNN/Transformer.

3 Lan truyền tiến (Forward Propagation)

Một MLP (*Multilayer Perceptron*) L lớp áp dụng liên tiếp phép biến đổi tuyến tính rồi phi tuyến. Ký hiệu $a^{(l)}$ là đầu ra (post-activation) của lớp l , $W^{(l)}, b^{(l)}$ là trọng số/bias của lớp l , f là hàm kích hoạt:

$$z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)}, \quad a^{(l)} = f(z^{(l)}), \quad a^{(0)} = x.$$

Lớp cuối $a^{(L)} = \hat{y}$ là dự đoán của mạng; với bài toán phân loại, lớp cuối thường *không* qua f phi tuyến mà giữ logits thô, để hàm mất mát (vd. Cross-Entropy) tự áp dụng softmax bên trong (tránh tính softmax hai lần và giúp gradient ổn định hơn về số học).

Ví dụ nhỏ: mạng 1 lớp ẩn, $x \in \mathbb{R}^2$, $W^{(1)} \in \mathbb{R}^{3 \times 2}$, $f = \text{ReLU}$: mỗi trong 3 neuron ẩn tính $z_j^{(1)} = W_{j,:}^{(1)} \cdot x + b_j^{(1)}$ rồi qua ReLU độc lập với nhau — forward pass chỉ đơn giản là lặp lại “nhân ma trận $\rightarrow$ cộng bias $\rightarrow$ áp activation” qua từng lớp. Mục 4.3 viết lại đúng phép tính này ở dạng ma trận cho cả một batch.

3.1 Softmax và Cross-Entropy: từ logits tới xác suất

Bài toán phân loại 10 lớp của báo cáo (Fashion-MNIST, Mục 7.1) cần lớp cuối trả về *phân phối xác suất* trên 10 lớp, không phải 10 số logits tùy ý. **Softmax** làm đúng việc

chuyển đổi này:

$$p_k = \text{softmax}(z)_k = \frac{e^{z_k}}{\sum_{j=1}^{10} e^{z_j}}, \quad k = 1, \dots, 10.$$

Cách hiểu đơn giản. e^{z_k} luôn dương, nên $p_k > 0$ với mọi k ; chia cho tổng đảm bảo $\sum_k p_k = 1$ — đúng định nghĩa một phân phối xác suất. Logit z_k càng lớn so với các z_j khác thì p_k càng gần 1 (mô hình càng “tự tin” lớp k đúng).

Cross-Entropy Loss so khớp phân phối dự đoán p với nhãn thật y (dạng one-hot — vector toàn 0 trừ vị trí lớp đúng = 1):

$$L = - \sum_{k=1}^{10} y_k \log p_k = -\log p_{y_{\text{true}}}$$

(vì $y_k = 0$ với mọi k trừ lớp đúng, nên tổng chỉ còn đúng một số hạng). L nhỏ khi $p_{y_{\text{true}}}$ (xác suất gán cho lớp đúng) gần 1; L lớn (tiến tới ∞) khi mô hình gán xác suất gần 0 cho lớp đúng — đúng trực giác “phạt nặng khi tự tin sai”.

Ví dụ số (rút gọn còn 3 lớp cho dễ theo dõi, logits $z = (2, 0; 0, 5; -1, 0)$, nhãn đúng là lớp 1):

$$p = (0,7856; 0,1753; 0,0391), \quad L = -\log(0,7856) = 0,2413.$$

Đạo hàm của Cross-Entropy kết hợp Softmax rút gọn đẹp bất ngờ — *không cần đạo hàm riêng từng hàm*, chain rule qua cả hai bước cho kết quả cực đơn giản:

$$\frac{\partial L}{\partial z} = p - y = (-0,2144; 0,1753; 0,0391)$$

(hiệu giữa xác suất dự đoán và one-hot nhãn thật) — đây chính là công thức $\delta_2 = \hat{y} - y$ đã dùng xuyên suốt Mục 4.2–4.3 của báo cáo (ở đó bài toán hồi quy 1 chiều nên $\hat{y} - y$ chỉ là hiệu số thường; với phân loại nhiều lớp, cùng công thức $\hat{y} - y$ áp dụng cho *vector* $p - y$). Đây là lý do PyTorch `CrossEntropyLoss` nhận logits thô (z) làm input thay vì xác suất đã qua softmax — áp dụng softmax và tính gradient trong *một* bước duy nhất, vừa nhanh hơn vừa tránh mất độ chính xác số học khi e^{z_k} rất lớn hoặc rất nhỏ.

Forward pass **không** liên quan gì đến gradient — nó chỉ tính đầu ra và lưu lại các giá trị trung gian ($z^{(l)}, a^{(l)}$) mà Backpropagation sẽ cần dùng lại ở Mục 4 (đây là lý do PyTorch autograd giữ một “computational graph” ngầm trong bộ nhớ suốt forward pass).

4 Lan truyền ngược (Backpropagation)

4.1 Trực giác (Intuition)

Cách hiểu đơn giản. Hãy tưởng tượng một dây chuyền sản xuất nhiều công đoạn, sản phẩm cuối bị lỗi. Muốn biết công đoạn nào “chịu trách nhiệm” bao nhiêu cho lỗi đó, ta đi *ngược* từ cuối dây chuyền về đầu, ở mỗi công đoạn hỏi: “*công đoạn này khuếch đại hay làm giảm lỗi bao nhiêu?*”, rồi nhân dồn các mức khuếch đại đó lại. Backpropagation làm đúng việc này cho một mạng nơ-ron: đi ngược từ loss về từng tham số, dùng Chain Rule tại mỗi bước.

Backpropagation không phải một thuật toán “thần kỳ” riêng biệt — nó là **Chain Rule áp dụng có hệ thống trên một computational graph**, tận dụng việc lưu lại (cache) giá trị forward để không phải tính lại từ đầu cho mỗi tham số. Thuật toán được phổ biến rộng rãi cho huấn luyện mạng nơ-ron nhiều lớp bởi Rumelhart et al. [1986], dù bản chất toán học (Chain Rule) đã có từ Giải tích cổ điển. Đây là điểm khác biệt với việc tính gradient bằng finite-difference (tính lại toàn bộ forward pass cho *từng* tham số một — xem Mục 4.4).

4.2 Scalar Derivation — ví dụ từ neuron đơn tới mạng 2 lớp


Bước 1 — một neuron (đã làm ở Mục 2.6). Với đồ thị $z = wx + b \rightarrow a = \text{ReLU}(z) \rightarrow L = \frac{1}{2}(a - y)^2$, ba đạo hàm cần cho huấn luyện là $\partial L / \partial w$, $\partial L / \partial b$ (cập nhật tham số) và $\partial L / \partial x$ (tiếp tục lan truyền ngược nếu có lớp trước đó) — xem Bảng 1.

Bước 2 — mạng 2 lớp. Xét kiến trúc (quy ước vector cột cho *một mẫu đơn lẻ*, quen thuộc sách giáo trình; Mục 4.3 sẽ đổi sang quy ước hàng-là-mẫu để khớp code):

$$x \rightarrow \text{Linear}(W_1, b_1) \rightarrow \text{ReLU} \rightarrow \text{Linear}(W_2, b_2) \rightarrow \hat{y} \rightarrow L,$$

với:

$$z_1 = W_1^T x + b_1, \quad a_1 = \text{ReLU}(z_1), \quad z_2 = W_2^T a_1 + b_2, \quad \hat{y} = z_2, \quad L = \frac{1}{2} \|\hat{y} - y\|^2.$$



Hình 3: Gradient đi ngược Loss $\rightarrow$ Output $\rightarrow$ Hidden $\rightarrow$ Input. Mỗi $\delta_l = \partial L / \partial z_l$ được tính một lần rồi dùng lại cho mọi tham số của lớp l — đây là điểm làm Backprop hiệu quả (Mục 4.4).

Backward:

$$\delta_2 = \frac{\partial L}{\partial z_2} = \hat{y} - y \quad (\text{output activation = identity})$$

$$\frac{\partial L}{\partial W_2} = a_1 \delta_2^T, \quad \frac{\partial L}{\partial b_2} = \delta_2, \quad \frac{\partial L}{\partial a_1} = W_2 \delta_2$$

$$\delta_1 = \frac{\partial L}{\partial z_1} = \frac{\partial L}{\partial a_1} \odot \text{ReLU}'(z_1)$$

$$\frac{\partial L}{\partial W_1} = x \delta_1^T, \quad \frac{\partial L}{\partial b_1} = \delta_1, \quad \frac{\partial L}{\partial x} = W_1 \delta_1$$

($\odot$ = nhân từng phần tử. Vì $a = f(z)$ tác động độc lập lên từng toạ độ, Jacobian của nó là ma trận đường chéo, nên nhân Jacobian-vector rút gọn thành nhân từng phần tử với $f'(z)$.)

Vì sao có δ_1, δ_2 riêng, không viết lại Chain Rule từ đầu mỗi lần? Mỗi δ_l “gộp sẵn” toàn bộ ảnh hưởng của các lớp phía sau nó; khi tính gradient cho W_1, b_1 chỉ cần nhân

δ_1 với input cục bộ (x) — không phải viết lại chuỗi nhân xuyên suốt từ L . Đây chính là điểm làm Backprop **hiệu quả**, không chỉ **đúng**.

Ví dụ số đã verify ($x = (1, 1)$, xem thiết lập tham số đầy đủ trong `experiments/toy_example_verify.py`):

Bảng 2: Forward/backward mạng 2 lớp — khớp PyTorch autograd (sai số = 0) và finite-difference (sai số $< 10^{-9}$)

Đại lượng	Giá trị
z_1	(0,60, -0,40, 0,30)
$a_1 = \text{ReLU}(z_1)$	(0,60, 0,00, 0,30) — neuron 2 “chết” ($z_1[2] < 0$)
$\hat{y} = z_2$	0,29
L	0,25205
δ_2	-0,71
$\partial L / \partial W_2$	(-0,426, 0,000, -0,213) ^T
δ_1	(-0,142, 0,000, -0,284)
$\partial L / \partial W_1$	hàng 1 = hàng 2 = (-0,142, 0,000, -0,284)
$\partial L / \partial x$	(-0,071, -0,071)

Điểm sơ phạm quan trọng. Cột thứ 2 của $\partial L / \partial W_1$ và $\partial L / \partial W_2$ đều bằng 0 — vì neuron 2 bị ReLU “khoá” ở forward ($z_1[2] = -0,4 < 0$) nên $\text{ReLU}'(z_1[2]) = 0$ chặn đứng toàn bộ gradient chảy qua neuron đó, bất kể δ phía sau lớn hay nhỏ. Đây là minh hoạ trực tiếp hiện tượng “**dead ReLU**”, sẽ nhắc lại ở Mục 5 và Mục 6.

4.3 Matrix Form (batch, khớp code NumPy/PyTorch)

Từ đây đổi quy ước: **hàng của X là một mẫu** — $X \in \mathbb{R}^{N \times n_0}$ với N = batch size (khớp `src/manual_nn.py` và mọi framework deep learning phổ biến):

$$Z^{(l)} = A^{(l-1)}W^{(l)} + b^{(l)} \in \mathbb{R}^{N \times n_l}, \quad A^{(l)} = f(Z^{(l)}), \quad A^{(0)} = X.$$

($b^{(l)} \in \mathbb{R}^{1 \times n_l}$ được **broadcast** — cộng vào mỗi trong N hàng như nhau; về mặt toán, tương đương nhân với vector cột toàn số 1: $\mathbf{1}_N b^{(l)}$.)

Backward (với $L = \frac{1}{N} \sum_i \text{loss}_i$ — trung bình theo batch, khớp `reduction='mean'` mặc định của PyTorch):

$$\begin{aligned} \frac{\partial L}{\partial Z^{(l)}} &= \frac{\partial L}{\partial A^{(l)}} \odot f'(Z^{(l)}) \in \mathbb{R}^{N \times n_l} \\ \frac{\partial L}{\partial W^{(l)}} &= (A^{(l-1)})^T \frac{\partial L}{\partial Z^{(l)}} \in \mathbb{R}^{n_{l-1} \times n_l} \\ \frac{\partial L}{\partial b^{(l)}} &= \mathbf{1}_N^T \frac{\partial L}{\partial Z^{(l)}} \in \mathbb{R}^{1 \times n_l} \quad (\text{tổng theo trục batch — hệ quả của broadcasting}) \\ \frac{\partial L}{\partial A^{(l-1)}} &= \frac{\partial L}{\partial Z^{(l)}} (W^{(l)})^T \in \mathbb{R}^{N \times n_{l-1}} \end{aligned}$$

Kiểm tra kích thước (lỗi hay gặp nhất khi code thủ công): $(n_{l-1} \times N)(N \times n_l) = n_{l-1} \times n_l$ khớp $W^{(l)}$; $(N \times n_l)(n_l \times n_{l-1}) = N \times n_{l-1}$ khớp $A^{(l-1)}$.

Quan hệ với Mục 4.2: cùng một phép tính, chỉ khác cách viết. Với $N = 1$ (bỏ batch): $Z_{\text{hàng}} = x^T W + b \Leftrightarrow z_{\text{cột}} = W^T x + b^T$ — chuyển vị của nhau. Đây là lý do `src/manual_nn.py` (Phần A — Manual Backpropagation, xem Mục 8) triển khai đúng công thức batch ở trên, còn ví dụ bằng tay ở Mục 4.2 dùng quy ước cột cho gọn.

Ví dụ số đầy đủ dạng ma trận (batch $N = 2$, kiến trúc $3 \rightarrow 2 \rightarrow 1$, ReLU — toàn bộ tính bằng NumPy và đối chiếu PyTorch autograd khớp tuyệt đối trong `experiments/toy_example_verify.py::example_matrix_batch`):

$$X = \begin{pmatrix} 1,0 & 0,5 & -1,0 \\ 0,0 & 1,0 & 2,0 \end{pmatrix}, \quad W^{(1)} = \begin{pmatrix} 0,2 & -0,1 \\ 0,4 & 0,3 \\ -0,5 & 0,2 \end{pmatrix}, \quad b^{(1)} = \begin{pmatrix} 0,1 & -0,2 \end{pmatrix}$$

$$W^{(2)} = \begin{pmatrix} 0,6 \\ -0,3 \end{pmatrix}, \quad b^{(2)} = \begin{pmatrix} 0,05 \end{pmatrix}, \quad Y = \begin{pmatrix} 1,0 \\ 0,0 \end{pmatrix}.$$

Forward:

$$Z^{(1)} = XW^{(1)} + b^{(1)} = \begin{pmatrix} 1,00 & -0,35 \\ -0,50 & 0,50 \end{pmatrix}, \quad A^{(1)} = \text{ReLU}(Z^{(1)}) = \begin{pmatrix} 1,00 & 0,00 \\ 0,00 & 0,50 \end{pmatrix}$$

$$\hat{Y} = A^{(1)}W^{(2)} + b^{(2)} = \begin{pmatrix} 0,65 \\ -0,10 \end{pmatrix}, \quad L = \frac{1}{2N} \sum_i \|\hat{y}_i - y_i\|^2 = 0,033125.$$

Backward:

$$\frac{\partial L}{\partial Z^{(2)}} = \frac{\hat{Y} - Y}{N} = \begin{pmatrix} -0,175 \\ -0,050 \end{pmatrix}, \quad \frac{\partial L}{\partial W^{(2)}} = (A^{(1)})^T \frac{\partial L}{\partial Z^{(2)}} = \begin{pmatrix} -0,175 \\ -0,025 \end{pmatrix}$$

$$\frac{\partial L}{\partial b^{(2)}} = \begin{pmatrix} -0,225 \end{pmatrix}, \quad \frac{\partial L}{\partial A^{(1)}} = \frac{\partial L}{\partial Z^{(2)}} (W^{(2)})^T = \begin{pmatrix} -0,105 & 0,0525 \\ -0,030 & 0,0150 \end{pmatrix}$$

$$\frac{\partial L}{\partial Z^{(1)}} = \frac{\partial L}{\partial A^{(1)}} \odot \text{ReLU}'(Z^{(1)}) = \begin{pmatrix} -0,105 & 0,000 \\ 0,000 & 0,015 \end{pmatrix}$$

$$\frac{\partial L}{\partial W^{(1)}} = X^T \frac{\partial L}{\partial Z^{(1)}} = \begin{pmatrix} -0,1050 & 0,000 \\ -0,0525 & 0,015 \\ 0,1050 & 0,030 \end{pmatrix}, \quad \frac{\partial L}{\partial b^{(1)}} = \begin{pmatrix} -0,105 & 0,015 \end{pmatrix}$$

Lưu ý cột 2 của $\partial L / \partial Z^{(1)}$ có phần tử 0 ở hàng 1 (vì $Z_{1,2}^{(1)} = -0,35 < 0$ — neuron đó “chết” với mẫu 1) trong khi cột 1 có phần tử 0 ở hàng 2 (vì $Z_{2,1}^{(1)} = -0,50 < 0$ — neuron kia “chết” với mẫu 2 khác) — minh họa dead ReLU xảy ra *độc lập theo từng cặp (mẫu, neuron)*, không phải một hiện tượng toàn cục.

4.4 Độ phức tạp tính toán (Computational Complexity)

Forward qua L lớp tốn $O(\sum_l n_{l-1} n_l)$ phép nhân (chi phí các phép nhân ma trận $A^{(l-1)} W^{(l)}$). Backward tái dùng đúng các số hạng đó (nhân với $(W^{(l)})^T$ và $(A^{(l-1)})^T$) nên có **cùng bậc chi phí** với forward — tổng backprop ≈ 2 –3 lần một lượt forward.

So sánh với cách tính gradient “ngây thơ” bằng finite-difference cho từng tham số: với P tham số, cần $O(P)$ lượt forward (nhích từng tham số một, tính lại loss). Với mạng vài triệu tham số, $O(P)$ lượt forward là không khả thi, trong khi Backprop chỉ cần $O(1)$ lượt forward + $O(1)$ lượt backward. **Đây là lý do Backprop là một “phát minh” quan trọng:** không phải vì nó cho kết quả đúng hơn (Chain Rule luôn đúng, finite-difference cũng xấp xỉ đúng) mà vì nó **hiệu quả hơn theo bậc độ lớn**. Mục 8.3 dùng finite-difference đúng theo cách “chậm nhưng đáng tin” này để kiểm tra lại Backprop tự viết.

Số liệu cụ thể cho kiến trúc của báo cáo ($784 \rightarrow 128 \times 6 \rightarrow 10$, Mục 7): tổng số tham số

$$P = \underbrace{784 \times 128 + 128}_{\text{lớp 1}} + \underbrace{5 \times (128 \times 128 + 128)}_{\text{5 lớp ẩn giữa}} + \underbrace{128 \times 10 + 10}_{\text{lớp output}} = 184,330.$$

Finite-difference cần $O(P) = 184\,330$ lượt forward *chỉ để tính gradient một lần* (một lượt cho mỗi tham số, cộng thêm 1 lượt gốc); trên CPU của báo cáo (một lượt forward batch 128 mẫu mất cỡ vài mili-giây), ước lượng thời gian cho *một bước* gradient descent theo cách này đã lên tới hàng phút — so với Backprop chỉ cần đúng 1 lượt forward + 1 lượt backward (dưới 1 giây), là chênh lệch **5 bậc độ lớn** về số lượt forward cần thiết. Đây là lý do 20 cấu hình thực nghiệm chính (Mục 9, tổng cộng $20 \times 15 = 300$ epoch huấn luyện) chạy xong trong ≈ 1 phút CPU bằng Backprop — với finite-difference, cùng khối lượng công việc sẽ mất hàng tháng.

4.5 Backpropagation vs. Gradient Descent

Đây là hai khái niệm **thường bị nhầm là một**, nhưng đóng hai vai trò hoàn toàn khác nhau:

Bảng 3: Phân biệt Backpropagation và Gradient Descent

	Backpropagation	Gradient Descent (và biến thể: SGD, Momentum, Adam,...)
Là gì	Thuật toán tính $\nabla_{\theta} L$ hiệu quả bằng Chain Rule + computational graph	Quy tắc cập nhật tham số dùng gradient đã có: $\theta \leftarrow \theta - \eta \nabla_{\theta} L$
Đầu vào	Đồ thị tính toán + giá trị forward đã lưu	Gradient (từ bất kỳ nguồn nào — Backprop, finite-difference,...)
Đầu ra	Vector gradient $\nabla_{\theta} L$	Tham số mới θ_{t+1}
Có thể thay bằng gì	Về nguyên tắc: finite-difference (chậm, $O(P)$ forward) — cùng kết quả, khác chi phí	Về nguyên tắc: Momentum, RMSProp, Adam [Kingma and Ba, 2015], Newton’s method — cùng “nguyên liệu” gradient, khác cách dùng

Chốt lại: Backpropagation *không* “huấn luyện” mạng — nó chỉ trả lời “*loss đang thay đổi thế nào theo từng tham số?*”. Gradient Descent/optimizer mới là bước quyết định “*vậy nên sửa tham số ra sao?*”. Trong dự án này (Mục 7), toàn bộ 20 cấu hình thực nghiệm

dùng *cùng một* Backpropagation (qua PyTorch autograd) và *cùng một* optimizer (SGD thuần) — biến duy nhất thay đổi là **initialization**, để cô lập đúng ảnh hưởng của θ_0 .

4.6 Các biến thể Gradient Descent (SGD, Momentum, Adam)

Bảng 3 liệt kê SGD/Momentum/Adam như các cách khác nhau để *dùng cùng một* gradient — dưới đây là công thức cụ thể, để làm rõ chúng khác nhau ở đâu (không dùng trong thực nghiệm chính, vốn cố định SGD thuần để cô lập biến initialization, nhưng cần thiết để hiểu đầy đủ Bảng 3 và trả lời câu hỏi “vậy Adam có thay thế được initialization tốt không?” ở Mục 10).

SGD thuần (dùng trong toàn bộ thực nghiệm của báo cáo):

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L_t.$$

Đơn giản, mỗi bước chỉ dùng gradient *hiện tại*, không “nhớ” gì từ các bước trước.

Momentum: tích lũy một “vận tốc” v_t — trung bình trượt có trọng số mũ của các gradient trước đó, giúp vượt qua các vùng dao động nhỏ (nhiều batch) và tăng tốc theo hướng nhất quán:

$$v_t = \beta v_{t-1} + (1 - \beta) \nabla_{\theta} L_t, \quad \theta_{t+1} = \theta_t - \eta v_t \quad (\beta \approx 0,9).$$

Adam [Kingma and Ba, 2015]: kết hợp Momentum (ước lượng bậc 1 m_t , giống v_t ở trên) với một ước lượng bậc 2 v_t (trung bình trượt của *bình phương* gradient) để **tự động chia tỷ lệ learning rate riêng cho từng tham số** — tham số có gradient lịch sử lớn được bước đi nhỏ lại, tham số có gradient nhỏ được bước đi lớn hơn:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\theta} L_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla_{\theta} L_t)^2,$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}, \quad \theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

($\hat{m}_t, \hat{v}_t$ là phiên bản đã hiệu chỉnh thiên lệch — *bias correction* — cho vài bước đầu khi $m_0 = v_0 = 0$; $\beta_1=0,9, \beta_2=0,999, \epsilon=10^{-8}$ là giá trị mặc định phổ biến).

Adam có “cứu” được initialization tồi không?. Không hoàn toàn. Chia tỷ lệ theo $\sqrt{\hat{v}_t}$ giúp Adam *bớt nhạy* với việc chọn sai learning rate toàn cục, nhưng nếu gradient ban đầu **đúng bằng 0** (Zero-init, Mục 5.2) thì $m_t = v_t = 0$ mãi mãi — Adam cũng bó tay như SGD, vì không có “nguyên liệu” gradient nào để chia tỷ lệ. Initialization và optimizer giải quyết hai vấn đề khác nhau (Mục 4.5) và không thể thay thế nhau hoàn toàn.

5 Khởi tạo tham số (Parameter Initialization)

5.1 Vì sao Initialization quan trọng

Cách hiểu đơn giản. Backpropagation cho biết *hướng* để sửa tham số, nhưng Gradient Descent chỉ di chuyển *cục bộ* quanh điểm xuất phát θ_0 . Chọn θ_0 sai có thể khiến mạng đứng yên mãi mãi (Mục 5.2) hoặc gradient nổ/biến mất trước khi kịp học (Mục 6) — bất kể optimizer tốt đến đâu.

5.2 Zero Initialization

Nếu **mọi** trọng số của một lớp giống hệt nhau (kể cả $= 0$): với cùng input x , mọi neuron trong lớp có cùng $z_j = w_j \cdot x + b_j$ (nếu bias cũng khởi tạo giống nhau) $\Rightarrow$ cùng a_j . Ở backward, mọi neuron nhận cùng δ_j và cùng input $\Rightarrow$ cùng gradient $\Rightarrow$ sau cập nhật, trọng số của chúng **vẫn giống hệt nhau**. Quy nạp theo từng bước huấn luyện: các neuron trong lớp mãi mãi tính cùng một hàm — lớp có n_l neuron chỉ có “sức biểu diễn” như 1 neuron. Đây gọi là **mất khả năng phá vỡ đối xứng** (*symmetry breaking*) [Goodfellow et al., 2016].

Với $W = 0$ cho *mọi* lớp (kể cả lớp output), phân tích còn mạnh hơn: $\partial L / \partial a^{(l-1)} = \delta^{(l)} (W^{(l)})^T = \delta^{(l)} \cdot 0 = 0$ với mọi lớp ẩn — gradient của *mọi* lớp ẩn bằng **đúng bằng 0**, không chỉ “rất nhỏ”. Chỉ lớp output (không có lớp nào phía sau để nhân với $W = 0$) còn nhận gradient khác 0 từ chính hàm loss. Mục 9 kiểm chứng đúng dự đoán này bằng số liệu thật (gradient đo được $= 0,0$ tuyệt đối tại mọi lớp ẩn khi khởi tạo Zero).

Ví dụ số truy vết 2 bước cập nhật (mạng $1 \rightarrow 2 \rightarrow 1$, activation linear để đơn giản, $x = 1$, $y = 1$, $\eta = 0,1$, mọi W, b khởi tạo 0):

Bảng 4: Truy vết 2 bước Gradient Descent với Zero-init — $W^{(1)}, W^{(2)}$ đứng yên tuyệt đối

Bước	$W^{(1)}$ (2 neuron)	$W^{(2)}$	$b^{(2)}$	L
Trước bước 1	(0,0; 0,0)	(0,0; 0,0)	0,00	0,500
Trước bước 2	(0,0; 0,0)	(0,0; 0,0)	0,10	0,405
Sau bước 2	(0,0; 0,0)	(0,0; 0,0)	0,19	—

Đúng như dự đoán: $W^{(1)}$ (2 trọng số vào 2 neuron ẩn) và $W^{(2)}$ **đứng yên tuyệt đối ở 0 qua cả 2 bước** ($dW^{(1)} = dW^{(2)} = 0$ luôn luôn) — hai neuron ẩn không bao giờ phân hoá. Toàn bộ việc “học” chỉ đến từ $b^{(2)}$ (bias lớp output, không bị vấn đề đối xứng vì chỉ có *một* neuron output) dịch chuyển dần $0 \rightarrow 0,1 \rightarrow 0,19$, kéo loss giảm nhẹ $0,500 \rightarrow 0,405$ — mạng “học” được một hằng số (giá trị trung bình của y), không học được bất kỳ đặc trưng nào của x , khớp đúng dự đoán lý thuyết ở trên và số liệu thực nghiệm thật ở Mục 9.

5.3 Random Initialization

Khởi tạo ngẫu nhiên (vd. $W \sim \mathcal{N}(0, \sigma^2)$ với σ nhỏ cố định, không tính theo kích thước lớp) phá vỡ đối xứng — mỗi neuron xuất phát khác nhau nên học các đặc trưng khác nhau. Nhưng nếu σ chọn tùy tiện, mạng **sâu** vẫn có thể vanish/explode (Mục 6): đây là động lực cho các scheme “khoa học” hơn bên dưới, vốn chọn σ dựa trên kích thước lớp thay vì một hằng số cố định.

Vì sao không đơn giản chọn σ lớn hơn? Đây là câu hỏi tự nhiên tiếp theo — nếu σ quá nhỏ gây vanishing (Mục 9: Random với $\sigma = 0,01$), tại sao không chọn σ lớn hơn để bù? Vấn đề là **không có một σ cố định nào đúng cho mọi kiến trúc**: hệ số nhân dồn $r = n_{\text{in}} \sigma^2$ (Mục 5.5) phụ thuộc *cả* σ *lẫn* n_{in} — cùng một σ có thể vanishing ở lớp rộng (n_{in} lớn $\Rightarrow r$ lớn hơn dự kiến, có thể explode) và exploding ở lớp hẹp cạnh đó, hoặc ngược lại. **Ý tưởng cốt lõi** của LeCun/Xavier/He (Mục 5.5) chính là: thay vì đoán một hằng số, tính σ *lại từ đầu cho mỗi lớp* dựa theo n_{in} (và n_{out}) của chính lớp đó, để $r \approx 1$ **đồng thời ở mọi lớp** bất kể kiến trúc rộng/hẹp ra sao — đây là bước nhảy về chất so với “random đơn thuần”, không chỉ là chọn số khác.

Giá trị mặc định trong framework thực tế: các thư viện Deep Learning phổ biến không dùng σ cố định kiểu “random ngây thơ” của báo cáo (vốn cố ý dùng làm đối chứng lý thuyết) mà mặc định sẵn một biến thể có scale theo n_{in} ngay từ đầu — `torch.nn.Linear` mặc định dùng phân phối Uniform theo biến thể Kaiming/He; Keras `Dense` mặc định dùng Glorot Uniform (cả hai không cần gọi hàm khởi tạo thủ công như Mục 8 nếu chấp nhận giá trị mặc định). Nói cách khác: **“Random (naive)” trong lưới thực nghiệm của báo cáo là trường hợp không ai dùng trong thực hành hiện đại** — được giữ lại có chủ đích như đường cơ sở lý thuyết (*baseline*) để làm nổi bật lý do các framework *không* dùng nó.

5.4 Trực giác fan_in , fan_out , $\text{Var}(W)$

$\text{fan_in} = n_{l-1}$ (số input của 1 neuron), $\text{fan_out} = n_l$ (số neuron ở lớp sau nhận input từ 1 neuron của lớp này). Với $z_j = \sum_{i=1}^{n_{\text{in}}} w_{ij}x_i$, nếu w_{ij}, x_i độc lập, kỳ vọng 0:


$$\text{Var}(z_j) = \sum_{i=1}^{n_{\text{in}}} \text{Var}(w_{ij}) \text{Var}(x_i) = n_{\text{in}} \cdot \text{Var}(W) \cdot \text{Var}(x).$$

Đây là **công thức trung tâm** của mọi scheme initialization: muốn giữ $\text{Var}(z) \approx \text{Var}(x)$ (không phóng đại/co hẹp tín hiệu forward qua mỗi lớp) thì cần $\text{Var}(W) = 1/n_{\text{in}}$. Phân tích tương tự cho backward (thay n_{in} bằng n_{out}) để giữ variance của gradient ổn định khi lan truyền ngược.

5.5 LeCun, Xavier/Glorot, He/Kaiming Initialization

Bảng 5: Các scheme initialization dùng trong báo cáo (và trong lưới thực nghiệm Mục 9)

Scheme	Công thức $\text{Var}(W)$	Activation phù hợp	Nguồn
Zero	0	Không dùng được	—
Random (naive)	σ^2 cố định, không theo n_{in}	Không khuyến nghị cho mạng sâu	thực hành phổ biến trước 2010
LeCun	$1/n_{\text{in}}$	Sigmoid/Tanh, input đã chuẩn hoá	LeCun et al. [2012]
Xavier/Glorot	$2/(n_{\text{in}} + n_{\text{out}})$	Tanh/Sigmoid (activation đối xứng quanh 0)	Glorot and Bengio [2010]
He/Kaiming	$2/n_{\text{in}}$	ReLU/Leaky ReLU	He et al. [2015]



Hình 4: Phân phối 10 000 giá trị W mô phỏng ngay sau khởi tạo theo từng scheme (lớp 128×128 , khớp $n_{\text{in}}=n_{\text{out}}=128$ của kiến trúc thực nghiệm Mục 7) — Zero co về một điểm; độ rộng phân phối tăng dần Random < LeCun = Xavier (khi $n_{\text{in}}=n_{\text{out}}$) < He, đúng thứ tự $\text{Var}(W)$ ở Bảng 5.

Vì sao He nhân đôi so với LeCun? ReLU đặt khoảng một nửa output về 0 (phần $z < 0$), nên với z đối xứng quanh 0: $\text{Var}(\text{ReLU}(z)) \approx \frac{1}{2}\text{Var}(z)$ — để bù phần “mất” này, He et al. [2015] nhân đôi variance của W so với công thức forward-preserving thuần ($1/n_{\text{in}}$) để giữ $\text{Var}(a) \approx \text{Var}(x)$ qua mỗi lớp ReLU.

Vì sao Xavier lấy trung bình n_{in} và n_{out} ? Phân tích forward (giữ $\text{Var}(z)$) cho $\text{Var}(W) = 1/n_{\text{in}}$; phân tích backward (giữ $\text{Var}(\partial L/\partial a)$ khi lan truyền ngược) cho $\text{Var}(W) = 1/n_{\text{out}}$. Hai điều kiện này chỉ trùng nhau khi $n_{\text{in}} = n_{\text{out}}$ (hiếm khi đúng trong thực tế); Glorot and Bengio [2010] chọn điểm dung hoà $\text{Var}(W) = 2/(n_{\text{in}} + n_{\text{out}})$ để không hy sinh hẳn điều kiện nào.

Bias: cả 3 scheme trên đều khởi tạo $b = 0$ — bias không gây vấn đề đối xứng *giữa các neuron* theo cùng cách W gây ra (mỗi b_j vẫn có thể học giá trị khác nhau miễn W đã phá đối xứng), nên giữ $b = 0$ là điểm khởi đầu trung tính, đơn giản, được dùng thống nhất trong toàn bộ thực nghiệm của báo cáo (Mục 7).

5.6 Chuỗi ảnh hưởng: Initialization $\rightarrow$ Training Stability

Initialization ($\text{Var}(W)$) $\Rightarrow$ Activation variance qua mỗi lớp
 $\Rightarrow$ Gradient variance khi lan truyền ngược
 $\Rightarrow$ Ổn định huấn luyện.

Nếu mỗi lớp nhân variance tín hiệu với hệ số $r = n_{\text{in}} \text{Var}(W)$ (bỏ qua hiệu chỉnh riêng của activation), sau L lớp: $\text{Var}(a^{(L)}) \approx r^L \cdot \text{Var}(x)$ — **tăng hoặc giảm theo hàm mũ của độ sâu** nếu $r \neq 1$. Đây chính là cơ chế toán học của vanishing/exploding gradient, trình bày chi tiết ở Mục 6.

5.7 Ví dụ số: lan truyền variance qua nhiều lớp

Áp công thức $r = n_{\text{in}} \text{Var}(W)$ (đã hiệu chỉnh cho từng activation) vào kiến trúc thực tế của báo cáo ($n_{\text{in}} = 128$ cho mọi lớp ẩn, xem Mục 7), giả sử $\text{Var}(x) = 1$ ở đầu vào lớp ẩn đầu tiên (Bảng 6 — tính lý tưởng hoá, bỏ qua hiệu ứng bão hoà thực tế của activation; số liệu *đo được thật* trên mạng thật nằm ở Hình 9, 10 Mục 9):

Bảng 6: $\text{Var}(a^{(l)})$ lý thuyết theo độ sâu l , ba scheme minh hoạ ($n_{\text{in}} = 128$)

Scheme	$l=0$	$l=1$	$l=2$	$l=3$	$l=4$	$l=5$	$l=6$
He+ReLU	1,00	1,00	1,00	1,00	1,00	1,00	1,00
Xavier+Tanh	1,00	1,00	1,00	1,00	1,00	1,00	1,00
Random	1,00	1,28e-2	1,64e-4	2,10e-6	2,68e-8	3,44e-10	4,40e-12

Ghi chú: hệ số nhân dồn mỗi lớp $r_{\text{eff}} \approx 1$ cho hai scheme đầu (theo thiết kế, Mục 5.5); $r = n_{\text{in}} \text{Var}(W) = 0,0128$ cho Random (naive, $\sigma = 0,01$ cố định, không hiệu chỉnh activation).

Với He/Xavier, hệ số r được *thiết kế* để xấp xỉ 1 nên variance tín hiệu giữ nguyên bậc-độ-lớn qua cả 6 lớp. Với Random (naive) ($\sigma = 0,01$ cố định $\Rightarrow r = 128 \times 0,01^2 = 0,0128$), variance suy giảm **10 bậc độ lớn** chỉ sau 6 lớp — khớp đúng bậc độ lớn với suy giảm gradient đo được thật trong Hình 8 (≈ 9 bậc từ lớp 7 về lớp 1), vì gradient và activation suy giảm theo cùng cơ chế nhân dồn (Mục 6).

5.8 Activation × Initialization: bảng tương thích

Bảng 7 tóm tắt khuyến nghị lý thuyết; Mục 9 kiểm chứng bằng lưới thực nghiệm đầy đủ $5 \times 4 = 20$ cấu hình — **không phải mọi khuyến nghị lý thuyết đều thành công như nhau trong thực nghiệm CPU/dữ liệu nhỏ của báo cáo này** (xem Mục 10).

Bảng 7: Khuyến nghị lý thuyết Activation × Initialization (không phải quy tắc tuyệt đối)

Activation	Initialization phù hợp và lý do
Sigmoid	Xavier/LeCun — hàm đối xứng quanh 0,5, nhưng $\sigma'(z) \leq 0,25$ luôn luôn nên vẫn dễ vanishing ở mạng sâu dù initialization đúng (Mục 6)
Tanh	Xavier — đối xứng quanh 0, đạo hàm cực đại = 1 tại $z = 0$, ít suy giảm hơn Sigmoid đáng kể
ReLU	He/Kaiming — bù trực tiếp việc ReLU triệt tiêu $\approx$ một nửa variance
Leaky ReLU	He/Kaiming (gần đúng) — tương tự ReLU, phần âm không hoàn toàn triệt tiêu nên ít “dead neuron” hơn

6 Vanishing và Exploding Gradient

Theo Chain Rule, gradient tại lớp đầu là **tích** của nhiều đạo hàm cục bộ dọc theo L lớp:

$$\frac{\partial L}{\partial a^{(0)}} = \frac{\partial L}{\partial a^{(L)}} \prod_{l=1}^L \frac{\partial a^{(l)}}{\partial a^{(l-1)}}.$$

Nếu độ lớn trung bình mỗi nhân tử cục bộ $\approx g$:

- $g < 1$: tích $\approx g^L \rightarrow 0$ theo hàm mũ khi L tăng — **vanishing gradient**: lớp đầu gần như không nhận được tín hiệu học.
- $g > 1$: tích $\approx g^L \rightarrow \infty$ — **exploding gradient**: bước cập nhật quá lớn, loss dao động hoặc NaN.
- $g = 1$: tích ổn định ở mọi độ sâu — mục tiêu mà Xavier/He hướng tới (Mục 5.5).

Bảng 8: Minh hoạ số: hệ số nhân dồn g^L theo độ sâu L (đã tính lại bằng `experiments/toy_example_verify.py`)

g	$L = 1$	$L = 5$	$L = 10$	$L = 20$	$L = 50$
0,5 (vanishing)	$5,0 \times 10^{-1}$	$3,1 \times 10^{-2}$	$9,8 \times 10^{-4}$	$9,5 \times 10^{-7}$	$8,9 \times 10^{-16}$
1,0 (ổn định)	1,0	1,0	1,0	1,0	1,0
2,0 (exploding)	2,0	$3,2 \times 10^1$	$1,0 \times 10^3$	$1,0 \times 10^6$	$1,1 \times 10^{15}$

Với $g = 0,5$, sau $L = 10$ lớp hệ số chỉ còn $\approx 1/1024$; sau $L = 50$ lớp gần như bằng 0 dưới độ chính xác số thực. Với $g = 2$, sau $L = 10$ lớp hệ số đã là 1024; sau $L = 50$ là hơn 10^{15} . Bảng 8 minh hoạ trực quan vì sao “giữ $g \approx 1$ ” (chính là mục tiêu của Xavier/He)


quan trọng với mạng sâu — một sai lệch nhỏ ở g bị **khuếch đại theo hàm mũ** của số lớp.

g phụ thuộc **cả ba yếu tố**: activation (hệ số co từ đạo hàm f' — vd. $\sigma'(z) \leq 0,25$ luôn luôn co lại), weight scale (qua $\text{Var}(W)$, Mục 5.5), và độ sâu L (số lần nhân). Thực nghiệm Mục 9 (Hình 8) đo trực tiếp gradient theo từng lớp trên mạng thật, xác nhận đúng ba yếu tố này cùng tác động.

Vì sao ReLU giúp giảm vanishing so với Sigmoid/Tanh. $\text{ReLU}'(z) \in \{0, 1\}$ — khi “sống” ($z > 0$), hệ số nhân đúng bằng 1 (không co lại như $\sigma'(z) \leq 0,25$); khi “chết” ($z \leq 0$), hệ số bằng 0 hoàn toàn (không “biến mất dần” mà “cắt đứt hẳn”). Đây là lý do ReLU không bị vanishing *do chính activation gây ra* như Sigmoid, nhưng đổi lại có rủi ro riêng: **dead ReLU** (neuron chết vĩnh viễn nếu rơi vào vùng $z \leq 0$ và không bao giờ nhận gradient để “sống lại” — đã thấy trong ví dụ Bảng 2).

6.1 Thực nghiệm bổ sung: độ sâu ảnh hưởng thế nào tới initialization

Lưới 20 cấu hình chính (Mục 9) cố định độ sâu = 6 lớp ẩn. Để kiểm chứng trực tiếp dự đoán lý thuyết của mục này — “*vanishing/exploding trầm trọng hơn theo hàm mũ của độ sâu*” — nhóm chạy thêm một thực nghiệm riêng (experiments/run_depth_experiment.py): so sánh **He** và **Random (naive)**, activation ReLU, tại **6 độ sâu khác nhau** $L \in \{2, 4, 6, 8, 10, 12\}$ lớp ẩn (rộng cố định 128), đo (a) gradient RMS lớp 1 *ngay tại bước khởi tạo* (không cần huấn luyện, đo nhanh và tách bạch khỏi hiệu ứng optimizer) và (b) test accuracy sau 8 epoch huấn luyện thật (rút ngắn so với 15 epoch của lưới chính để tổng thời gian hợp lý với $6 \times 2 = 12$ cấu hình bổ sung).



Hình 5: Gradient RMS lớp 1 tại khởi tạo (trái) và test accuracy sau 8 epoch (phải), theo độ sâu mạng, activation ReLU. Đường chấm ở đồ thị phải = mức ngẫu nhiên (10%).

Ba quan sát chính (Hình 5):

1. **Random (naive) suy giảm gradient theo đúng đường thẳng trên thang log** khi độ sâu tăng tuyến tính — từ $\approx 8,3 \times 10^{-5}$ ($L=2$) xuống $\approx 5,7 \times 10^{-16}$ ($L=12$), tức **suy giảm 12 bậc độ lớn chỉ sau 10 lớp thêm vào** — xác nhận trực tiếp mô hình g^L (Mục 6, Bảng 8): trên thang log, $\log(g^L) = L \log g$ là một đường thẳng theo L , đúng như đồ thị cho thấy.

2. **Test accuracy của Random sụp xuống mức ngẫu nhiên ngay từ $L=4$** — chỉ cần tăng độ sâu từ 2 lên 4 lớp là đủ để một initialization “tạm chấp nhận được” ở mạng nông (52% ở $L=2$, đã kém nhưng còn học được chút ít) trở thành hoàn toàn vô dụng.
3. **He giữ gradient ổn định (bậc 10^{-2}) ở mọi độ sâu từ 2 đến 10 lớp**, đúng như thiết kế của Mục 5.5. Tuy nhiên tại $L=12$, test accuracy của He **giảm mạnh xuống** 32,6% (dù gradient tại khởi tạo vẫn bình thường, $\approx 4 \times 10^{-2}$) — cho thấy **bản thân công thức $\text{Var}(\mathbf{W})$ đúng không đủ để đảm bảo hội tụ ổn định ở mạng cực sâu** khi chỉ dùng SGD thuần không có thêm kỹ thuật ổn định (Batch Normalization, residual connection). Đây chính là động lực lịch sử cho kiến trúc **ResNet** (*skip connection*) và **Batch/Layer Normalization** — initialization tốt giải quyết *điểm xuất phát*, nhưng mạng càng sâu thì *quỹ đạo hội tụ* càng cần thêm cơ chế ổn định khác, một hạn chế đã nêu ở Mục 11.


7 Phương pháp thực nghiệm

Mục tiêu: kiểm chứng bằng số liệu thật (không minh họa suông) ba dự đoán lý thuyết của Mục 5–6: (a) Zero/Random (naive) không học được; (b) initialization có scale đúng (LeCun/Xavier/He) học tốt hơn rõ rệt; (c) gradient theo từng lớp thể hiện đúng mẫu vanishing/exploding dự đoán bởi lý thuyết.

7.1 Dataset và tiền xử lý

Fashion-MNIST [Xiao et al., 2017] qua `torchvision`: ảnh 28×28 xám, 10 lớp trang phục, cân bằng số lượng giữa các lớp. Chọn thay MNIST chữ số thuần vì MNIST quá dễ (một MLP nông cũng đạt $> 97\%$), làm mờ tác động của initialization đang muốn khảo sát; Fashion-MNIST khó hơn vừa đủ để 5 scheme initialization tạo ra khác biệt rõ ràng mà vẫn đủ nhẹ để chạy nhanh trên CPU.

Fashion-MNIST — mẫu ảnh thật theo từng lớp (8 mẫu/lớp)



Hình 6: Mẫu ảnh thật của cả 10 lớp Fashion-MNIST (8 mẫu/lớp, lấy ngẫu nhiên từ tập train đang dùng).

Bảng 9: 10 lớp của Fashion-MNIST

0	T-shirt/top	4	Coat	8	Bag
1	Trouser	5	Sandal	9	Ankle boot
2	Pullover	6	Shirt		
3	Dress	7	Sneaker		

Subset để chạy nhanh trên CPU (khai báo minh bạch, không giấu): 5 000 mẫu train / 1 000 val / 2 000 test, lấy ngẫu nhiên *cân bằng theo lớp* (*stratified sampling* — mỗi lớp góp số mẫu bằng nhau, tránh lệch phân phối khi cắt subset từ 60 000 mẫu gốc), seed cố định = 42.

Tiền xử lý: mỗi ảnh làm phẳng thành vector 784 chiều ($28 \times 28 \rightarrow 784$, khớp input của MLP, Mục 3), giá trị pixel gốc $\in [0, 255]$ chia 255 về $[0, 1]$, sau đó chuẩn hoá $(\text{pixel} - \mu) / \sigma$ với $\mu = 0,2881$, $\sigma = 0,3543$ — **tính trực tiếp từ chính 5 000 mẫu train đang dùng** (không tra số liệu chuẩn hoá từ nguồn khác) để tránh rò rỉ thông tin từ phần dữ liệu không dùng tới huấn luyện.

7.2 Kiến trúc mô hình

MLP 6 hidden layer, **cố định cho mọi cấu hình**, không BatchNorm/Dropout, không pretrained:

$$784 \rightarrow 128 \rightarrow 128 \rightarrow 128 \rightarrow 128 \rightarrow 128 \rightarrow 128 \rightarrow 10.$$

Lớp output luôn linear (logits), dùng **CrossEntropyLoss** (softmax nằm trong hàm loss). Độ sâu 6 lớp ẩn được chọn **cố ý đủ sâu** để chênh lệch giữa các initialization thể hiện rõ (một MLP 1–2 lớp gần như không nhạy với initialization, xem thảo luận Mục 10) mà vẫn huấn luyện nhanh trên CPU.

7.3 Thiết kế lưới thực nghiệm

Biến thực nghiệm (fair experiment): lưới đầy đủ 5 initialization $\times$ 4 activation = 20 cấu hình (Bảng 10) — *chỉ* initialization và activation thay đổi; kiến trúc, optimizer, learning rate, batch size, epoch, seed, cách chia dữ liệu giống hệt nhau giữa 20 lần chạy.

Bảng 10: Lưới thực nghiệm $5 \times 4 = 20$ cấu hình (Experiment 1–8 đều rút ra từ lưới này)

	Sigmoid	Tanh	ReLU	Leaky ReLU
Zero	✓	✓	✓	✓
Random (naive)	✓	✓	✓	✓
LeCun	✓	✓	✓	✓
Xavier/Glorot	✓	✓	✓	✓
He/Kaiming	✓	✓	✓	✓

Ánh xạ sang 8 experiment theo đề cương: Exp. 1–5 (Zero/Random/LeCun/Xavier/He) = cột **ReLU**; Exp. 6 (so sánh activation) = hàng **He** và hàng **Xavier**; Exp. 7 (gradient norm theo layer) = lát cắt **Sigmoid** (nơi vanishing rõ nhất về lý thuyết); Exp. 8 (training convergence) = loss/accuracy theo epoch của chính 20 lần chạy trên.

Bảng 11: Siêu tham số cố định cho toàn bộ 20 cấu hình

Optimizer	SGD thuần (không momentum)
Learning rate η	0,05
Batch size	128
Epochs	15
Seed	42 (Python, NumPy, PyTorch)
Bias init	0 (mọi scheme)
Loss	CrossEntropyLoss

SGD thuần (không Adam) được chọn **cố ý**: optimizer thích ứng (adaptive) như Adam có learning rate riêng cho từng tham số, có thể che bớt một phần ảnh hưởng của initialization kém — dùng SGD thuần để quan sát đúng hiệu ứng lý thuyết Mục 5–6, đánh đổi lấy khả năng hội tụ chậm hơn/không ổn định hơn ở một số cấu hình (thảo luận ở Mục 11).

7.4 Metric thu thập

Metric thu thập: mỗi epoch — train/val loss, train/val accuracy; tại **bước đầu tiên** (trước update đầu tiên) — gradient RMS theo từng lớp, activation mean/variance theo từng lớp, weight mean/variance theo từng lớp, cùng một mẫu gradient/activation thô ở lớp giữa mạng (để vẽ histogram).

Vì sao dùng RMS thay vì norm thô để so sánh giữa các lớp? Lớp 1 ($784 \rightarrow 128$) có 100 352 phần tử W , các lớp ẩn giữa ($128 \rightarrow 128$) chỉ có 16 384 — so trực tiếp $\|\partial L / \partial W\|_2$ (norm Frobenius thô) giữa hai lớp này bị lệch chỉ vì kích thước ma trận khác nhau, không phản ánh đúng ”độ lớn gradient mỗi trọng số”. Báo cáo dùng **RMS** (*root-mean-square*), chuẩn hoá theo số phần tử:

$$\text{RMS}\left(\frac{\partial L}{\partial W^{(l)}}\right) = \frac{\|\partial L / \partial W^{(l)}\|_2}{\sqrt{|W^{(l)}|}}$$

($|W^{(l)}|$ = tổng số phần tử của $W^{(l)}$) — đây chính là đại lượng vẽ trong Hình 8, 5, cho phép so sánh công bằng giữa các lớp có kích thước khác nhau (chi tiết cài đặt: hàm `grad_norms_per_layer` trong `src/metrics.py`).

8 Hiện thực

Mã nguồn đầy đủ nằm trong `src/` (module hoá) và `experiments/` (script chạy) — xem cấu trúc trong `README.md`. Hai phần quan trọng nhất:

8.1 Part A: Manual Backpropagation

Part A — Manual Backpropagation (`src/manual_nn.py`): forward/backward tự viết bằng NumPy thuần, **không dùng autograd**, triển khai đúng công thức Mục 4.3:

Listing 1: Backward pass thủ công (trích từ `src/manual_nn.py`)

```
dA = (Yhat - Y) / N          # dL/dA^(L)
for l in reversed(range(n_layers)):
    is_last = (l == n_layers - 1)
    dZ = dA if is_last else dA * f_grad(Zs[l])
    grads_W[l] = As[l].T @ dZ # A^(l-1)^T dZ^(l)
    grads_b[l] = dZ.sum(axis=0) # tong theo truc batch
    dA = dZ @ W[l].T          # dL/dA^(l-1)
```

8.2 Part B: PyTorch Autograd

Part B — PyTorch Autograd (`src/models.py`, `src/training.py`): kiến trúc tương đương dùng `torch.nn`, gradient tính bằng `loss.backward()` — cơ chế *automatic differentiation* của PyTorch [Paszke et al., 2019], về bản chất cũng là Backpropagation (Mục 4) nhưng tự động xây và duyệt computational graph thay vì viết tay như Part A; dùng cho toàn bộ 20 cấu hình thực nghiệm chính (Mục 7) vì cần training thật trên Fashion-MNIST, không khả thi bằng NumPy thuần trong phạm vi báo cáo.

Listing 2: Định nghĩa MLP và khởi tạo lại theo scheme (trích từ src/models.py)

```
class MLP(nn.Module):
    def __init__(self, input_dim=784, hidden_dims=None,
                  output_dim=10, activation="relu"):
        super().__init__()
        hidden_dims = hidden_dims or [128] * 6
        dims = [input_dim] + list(hidden_dims)
        self.linears = nn.ModuleList(
            [nn.Linear(dims[i], dims[i+1]) for i in range(len(dims)-1)])
        self.output = nn.Linear(dims[-1], output_dim)
        act_factory = ACTIVATION_MODULES[activation]
        self.activations = nn.ModuleList(
            [act_factory() for _ in range(len(self.linears))])

    def apply_initialization(self, scheme):
        # Ghi đè init mặc định của PyTorch bằng dùng scheme đang khảo sát
        for linear in self.linears:
            init_linear_(linear, scheme)
        init_linear_(self.output, scheme)
```

Mỗi `nn.Linear` được lưu *riêng* trong `ModuleList` (không gộp vào `nn.Sequential`) để `src/metrics.py` có thể đọc gradient/activation theo *từng lớp* sau `loss.backward()` — đây chính là cơ chế tạo ra Hình 8, 9, 10 (Mục 9).

Listing 3: Vòng lặp huấn luyện, rút gọn (trích từ src/training.py)

```
def train_one_config(activation, scheme, data, epochs, lr, ...):
    set_seed(seed) # tại lap: Python, NumPy, PyTorch
    model = MLP(activation=activation, hidden_dims=hidden_dims)
    model.apply_initialization(scheme) # DUY NHAT biến này thay đổi
    criterion = nn.CrossEntropyLoss()
    optimizer = torch.optim.SGD(model.parameters(), lr=lr)

    for epoch in range(1, epochs + 1):
        model.train()
        for xb, yb in train_loader:
            optimizer.zero_grad()
            logits = model(xb)
            loss = criterion(logits, yb)
            loss.backward() # Backpropagation (Mục 4)
            optimizer.step() # Gradient Descent (Mục 4.5)
        val_loss, val_acc = evaluate(model, val_loader, criterion)
        history.append({"epoch": epoch, "val_loss": val_loss, ...})
```

Dòng `loss.backward()` và `optimizer.step()` nằm cạnh nhau trong code nhưng thực hiện **hai việc tách biệt hoàn toàn** (Mục 4.5): dòng đầu chỉ *tính* gradient (ghi vào `.grad` của từng tham số, không đổi giá trị tham số); dòng sau mới thực sự *cập nhật* tham số dùng gradient vừa tính. Tách rời hai lệnh này trong mã nguồn phản ánh đúng ranh giới lý thuyết giữa Backpropagation và Gradient Descent đã nhấn mạnh xuyên suốt báo cáo.

8.3 Kiểm tra tính đúng đắn: Gradient Checking

Gradient Checking (`experiments/run_gradient_check.py`): đối chiếu ba cách tính gradient trên cùng một mạng, cùng một batch: (1) manual (NumPy), (2) PyTorch autograd (xây một bản sao dùng đúng trọng số của mạng manual, để so sánh công bằng), (3) finite-difference $(f(w+h) - f(w-h))/(2h)$, $h = 10^{-6}$.

Bảng 12: Kết quả Gradient Checking (mạng $6 \rightarrow 8 \rightarrow 5 \rightarrow 1$, activation Tanh)

Lớp	Kích thước W	max manual-autograd	max rel. error (vs. finite-diff)
0	6×8	$4,39 \times 10^{-9}$	$3,90 \times 10^{-9}$
1	8×5	$6,35 \times 10^{-9}$	$7,60 \times 10^{-9}$
2	5×1	$4,71 \times 10^{-9}$	$3,37 \times 10^{-9}$

Sai số tối đa ($\approx 10^{-9}$) nằm ở mức sai số làm tròn số thực (float64), **không phải sai số thuật toán** — kết quả **PASS** với ngưỡng chấp nhận 10^{-4} (log đầy đủ: `results/logs/gradient_check_report.json`). Gradient checking hữu ích chính vì nó **cô lập lỗi**: nếu manual sai (sai chiều ma trận, quên chia batch, sai dấu...) trong khi autograd và finite-diff vẫn khớp nhau, ta biết ngay lỗi nằm ở khâu tính gradient thủ công — không cần debug toàn bộ vòng lặp huấn luyện.


9 Kết quả thực nghiệm

Toàn bộ số liệu mục này lấy trực tiếp từ `results/tables/initialization_comparison.csv` và `results/logs/run_*.json` (20 file, sinh bởi `experiments/run_initialization.py`, tổng thời gian chạy ≈ 1 phút CPU) — không có số liệu minh hoạ hay ước lượng bằng tay.

9.1 Bức tranh tổng thể: test accuracy

Bảng 13: Test accuracy sau 15 epoch, toàn bộ 20 cấu hình

	Sigmoid	Tanh	ReLU	Leaky ReLU
Zero	0,100	0,100	0,100	0,100
Random (naive)	0,100	0,100	0,100	0,100
LeCun	0,100	0,689	0,638	0,648
Xavier/Glorot	0,100	0,692	0,674	0,682
He/Kaiming	0,100	0,694	0,667	0,634



Hình 7: Test accuracy, toàn bộ lưới 5×4 (đường chấm = mức ngẫu nhiên 10%).

Ba quan sát chính (Hình 7, Bảng 13):

1. **Zero và Random (naive) không bao giờ vượt mức ngẫu nhiên (10%)**, với *mọi* activation — khớp dự đoán lý thuyết Mục 5.2 (Zero: gradient lớp ẩn $\equiv 0$) và Mục 5.3 (Random không scale theo n_{in} nên vẫn vanishing ở độ sâu 6 lớp).
2. **Sigmoid thất bại với MỌI initialization**, kể cả He/Xavier vốn “đúng lý thuyết” cho các activation khác. Mục 10 phân tích nguyên nhân bằng chính số liệu gradient đo được.
3. **LeCun/Xavier/He đều hoạt động tốt với Tanh/ReLU/Leaky ReLU** (64–69%), chênh lệch giữa 3 scheme này nhỏ hơn nhiều so với chênh lệch Zero/Random vs. có-scale — khớp việc cả ba đều bảo toàn variance tín hiệu đúng bậc-độ-lớn, chỉ khác hệ số nhân (1 so với 2).

Đọc chi tiết theo từng activation (cột của Bảng 13)

Cột Sigmoid. Cả 5 scheme đều dừng ở 10,0% — không có “người thắng”. Đây không phải lỗi thực nghiệm (đã kiểm tra: mọi cấu hình sigmoid đều hội tụ về đúng cùng một điểm bias-only, xem thảo luận cơ chế chính xác ở Mục 10). Điểm đáng chú ý: *ngay cả về mặt số học*, 5 giá trị test accuracy của cột này giống nhau tới 3 chữ số thập phân dù xuất phát từ 5 initialization khác hẳn nhau — gợi ý mạng học được đúng *một* hàm hằng số (dự đoán theo tần suất lớp), không phân biệt được input, bất kể initialization.


Cột Tanh. Kết quả tốt nhất trong toàn lưới (He: 69,4%, Xavier: 69,2%, LeCun: 68,9%) — khớp lý thuyết: Tanh có đạo hàm cực đại = 1 tại $z = 0$ (so với 0,25 của Sigmoid), ít suy giảm tín hiệu nhất trong 4 activation được thử, nên “tha thứ” cho sai lệch nhỏ giữa 3 scheme LeCun/Xavier/He hơn.

Cột ReLU. Xavier dẫn đầu nhẹ (67,4%) trước He (66,7%) và LeCun (63,8%) — như đã thảo luận (Mục 10), chênh lệch Xavier/He nằm trong biên độ nhiễu 1-seed, không nên diễn giải quá mức. LeCun rõ ràng thấp hơn hẳn 2 scheme kia — hợp lý vì LeCun không có hệ số bù $\times 2$ cho việc ReLU triệt tiêu nửa variance (Mục 5.5).

Cột Leaky ReLU. Xavier tốt nhất (68,2%), He giảm xuống 63,4% (thấp hơn cả ReLU thường) — điểm bất ngờ nhẹ, vì Leaky ReLU có $\text{Var}(a)$ nhỉnh hơn ReLU (phần $z < 0$ không hoàn toàn về 0, xem Mục 6), nên hệ số bù $\times 2$ của He có thể hơi “*quá tay*” cho Leaky ReLU cụ thể ở kiến trúc/learning-rate này — một giả thuyết hợp lý nhưng

cần thêm thực nghiệm nhiều seed để xác nhận chắc chắn (không kiểm chứng thêm trong phạm vi báo cáo, Mục 11).


9.2 Gradient norm theo layer (Experiment 7)



Hình 8: RMS gradient mỗi trọng số theo layer, bước đầu tiên, activation Sigmoid (thang log). Đường “Zero” không hiện được vì gradient đúng bằng 0 tại 6 lớp ẩn (Mục 5.2) — log của 0 không xác định.

Hình 8 là bằng chứng thực nghiệm rõ nhất cho Mục 6: **Random (naive)** suy giảm gần **9 bậc độ lớn** từ lớp 7 (output) về lớp 1 (gần input), từ $\approx 10^{-2}$ xuống $\approx 3 \times 10^{-11}$ — vanishing gradient kinh điển do $\sigma = 0,01$ không được scale theo $n_{\text{in}} = 128$. **LeCun/Xavier/He** suy giảm nhẹ hơn nhiều (khoảng 2–3 bậc độ lớn) nhưng *vẫn suy giảm* vì bản thân $\sigma'(z) \leq 0,25$ (Sigmoid) co tín hiệu lại ở mỗi lớp bất kể weight scale đã đúng.


9.3 Activation variance theo layer



Hình 9: Phương sai activation theo layer, bước đầu tiên, activation Sigmoid (thang log).

Variance activation của Random (naive) ổn định ở mức rất thấp ($\approx 2-3 \times 10^{-4}$) ngay từ lớp 2 trở đi — các neuron gần như bão hoà quanh $\sigma(0) = 0,5$ với biến thiên cực nhỏ, giải thích trực tiếp vì sao gradient (Hình 8) cũng vanish nặng: activation gần như hằng số $\Rightarrow$ không mang thông tin phân biệt các mẫu. LeCun/Xavier/He giữ variance cao hơn hẳn (10^{-2}), ổn định qua các lớp.


9.4 Weight variance theo layer



Hình 10: Phương sai trọng số theo layer (đo thực tế ngay sau khởi tạo, activation ReLU).

Hình 10 xác nhận việc lấy mẫu $W \sim \mathcal{N}(0, \text{Var}(W))$ trong `src/initialization.py` đúng như công thức Bảng 5: variance do được của He luôn cao hơn Xavier, cao hơn LeCun, ở *mọi* lớp (thứ tự $2/n_{\text{in}} > 2/(n_{\text{in}} + n_{\text{out}}) > 1/n_{\text{in}}$ khi $n_{\text{in}} = n_{\text{out}}$ — đúng cho 5/6 lớp ẩn có cùng kích thước 128×128).


9.5 Loss và Accuracy theo epoch (Experiment 8)




Hình 11: Loss (trái) và validation accuracy (phải) theo epoch, activation ReLU. Zero/Random nằm sát mức ngẫu nhiên (đường chấm) suốt 15 epoch.

LeCun/Xavier/He hội tụ nhanh (accuracy > 60% ngay từ epoch 4–5) nhưng validation loss/accuracy dao động khá mạnh giữa các epoch — tập validation chỉ 1000 mẫu (nhiều thống kê đáng kể) cộng với không có learning-rate decay/momentum để làm mượt quỹ đạo hội tụ (thảo luận thêm ở Mục 11).

9.6 Phân phối gradient và activation (histogram)



Hình 12: Phân phối gradient tại lớp giữa mạng (lớp 3), activation Sigmoid, 5 scheme.




Hình 13: Phân phối activation tại lớp giữa mạng (lớp 3), activation Sigmoid, 5 scheme.

Histogram gradient (Hình 12) của Random (naive) có cụm sát 0 với biên độ nhỏ hơn nhiều bậc so với LeCun/Xavier/He — cùng một hiện tượng vanishing nhìn từ góc phân phối thay vì trung bình/norm. Histogram activation (Hình 13) của Zero có cụm hoàn toàn tại 0,5 (hằng số, đúng như phân tích Mục 5.2: $a = \sigma(0) = 0,5$ với mọi mẫu vì $z \equiv 0$).

9.7 Toàn cảnh: loss theo epoch của cả 20 cấu hình

Các Hình 11–13 chỉ trích một lát cắt (1 activation) để dễ đọc. Hình 14 trình bày **toàn bộ lưới** $5 \times 4 = 20$ cùng lúc, mỗi ô một cấu hình — để người đọc tự kiểm chứng không có cấu hình nào bị “chọn đẹp” (*cherry-picking*) khi báo cáo chỉ trưng lát cắt ReLU/Sigmoid ở các mục trước.



Hình 14: Loss theo epoch, toàn bộ 20 cấu hình (hàng = scheme, cột = activation; nét liền = train, nét đứt = validation; trục tung cắt ở 2,5 để các đường hội tụ không bị nén). Hai hàng Zero/Random phẳng tuyệt đối ở mọi cột — xác nhận trực quan Bảng 13 không có ngoại lệ ẩn nào ngoài lát cắt đã trình bày.

Quan sát thêm không thấy rõ ở các lát cắt trước: với cột **ReLU** và **Leaky ReLU**, validation loss của LeCun/Xavier/He đều dao động mạnh và có xu hướng **tăng nhẹ trở lại** sau epoch ≈ 10 trong khi train loss tiếp tục giảm đều — dấu hiệu *overfitting nhẹ* (model bắt đầu khớp quá sát 5 000 mẫu train, không cải thiện thêm trên val) ở nửa sau quá trình huấn luyện. Đây là hành vi bình thường của một MLP không regularization trên tập train nhỏ, không phải triệu chứng của vanishing/exploding gradient — một điểm dễ nhầm nếu chỉ nhìn một lát cắt đơn lẻ.

10 Thảo luận

10.1 Vì sao Sigmoid thất bại ngay cả với He/Xavier?

Đây là kết quả đáng chú ý nhất của thực nghiệm (Bảng 13): lý thuyết Mục 5.5 nói He/Xavier “bảo toàn variance tín hiệu”, nhưng điều đó chỉ đúng về *weight scale* — nó

không thể bù cho việc $\sigma'(z) \leq 0,25$ **luôn luôn đúng**, bất kể variance của z là bao nhiêu. Với 6 lớp, hệ số suy giảm trần do riêng activation gây ra đã là $0,25^6 \approx 2,4 \times 10^{-4}$ — cộng thêm 15 epoch với SGD thuần ($\eta = 0,05$, không momentum) là không đủ để vượt qua mức suy giảm này trong thời gian huấn luyện ngắn của báo cáo. Số liệu Mục 9 xác nhận đúng cơ chế này: gradient RMS lớp 1 của Sigmoid+He chỉ $\approx 1,6 \times 10^{-5}$ (so với $\approx 2,8 \times 10^{-2}$ của ReLU+He) — khác 0 (không “chết” như Zero-init) nhưng quá nhỏ để tạo ra bước cập nhật đáng kể ở LR đang dùng.

Bài học: initialization tốt là *điều kiện cần*, không phải *điều kiện đủ*, để tránh vanishing gradient. Với activation bão hoà (Sigmoid) ở mạng đủ sâu, cần thêm các biện pháp khác (nhiều epoch hơn, learning rate cao hơn, Batch Normalization, hoặc đơn giản là đổi sang ReLU/Tanh) — đây chính là lý do lịch sử Deep Learning dần bỏ Sigmoid làm activation ẩn cho mạng sâu, dù Sigmoid vẫn còn hữu ích ở lớp output cho bài toán phân loại nhị phân.

10.2 Đối chiếu dự đoán lý thuyết với số liệu

So với lý thuyết ở Mục 5.5–6: dự đoán “Zero/Random thất bại, LeCun/Xavier/He thành công với Tanh/ReLU” khớp hoàn toàn với thực nghiệm, ở cả lưới chính (Mục 9) lẫn thực nghiệm độ sâu bổ sung (Mục 6.1). Dự đoán “He tốt hơn Xavier cho ReLU” **không** được xác nhận rõ ràng ở quy mô thực nghiệm này (He: 66,7%, Xavier: 67,4% — chênh lệch nằm trong biên độ nhiễu của một seed/15 epoch duy nhất); đây là giới hạn hợp lý của thực nghiệm nhỏ, không phải bằng chứng bác bỏ lý thuyết (Mục 11). Kết quả thực nghiệm độ sâu (Mục 6.1) bổ sung một phát hiện lý thuyết *chưa* dự đoán trực tiếp: ngay cả He cũng có thể mất ổn định ở độ sâu rất lớn ($L=12$) dù gradient tại khởi tạo vẫn bình thường — cho thấy phân tích variance tĩnh (Mục 5) là điều kiện cần cho bước khởi tạo, nhưng không mô tả đầy đủ toàn bộ quỹ đạo hội tụ nhiều bước sau đó.

10.3 Liên hệ tới kiến trúc hiện đại

Bảng khuyến nghị Mục 5.5 (Bảng 7) vẫn là điểm khởi đầu hợp lý khi thiết kế mạng mới, nhưng kết quả Mục 9, 6.1 nhắc nhở rằng với activation bão hoà hoặc mạng rất sâu, initialization một mình không đủ. Đây chính là động lực của ba kỹ thuật phổ biến trong kiến trúc hiện đại, mỗi kỹ thuật giải quyết một khía cạnh khác của cùng vấn đề “gradient chảy qua mạng sâu”:

- **Batch/Layer Normalization:** chuẩn hoá lại phân phối $z^{(l)}$ sau mỗi lớp, không chỉ dựa vào việc chọn đúng $\text{Var}(W)$ một lần lúc khởi tạo — giảm mạnh độ nhạy với cả initialization lẫn learning rate trong suốt quá trình huấn luyện, không chỉ tại bước đầu.
- **Residual connection** (ResNet và hầu hết kiến trúc sâu hiện đại, gồm cả Transformer): thêm đường tắt $a^{(l)} = a^{(l-1)} + F(a^{(l-1)})$ — khi lan truyền ngược, $\partial a^{(l)} / \partial a^{(l-1)} = I + \partial F / \partial a^{(l-1)}$ luôn có thành phần I (ma trận đơn vị) cộng thêm, nên gradient có một “đường đi tắt” không bị nhân suy giảm qua F , giảm hẳn vấn đề vanishing theo cấp số nhân của Mục 6 kể cả khi mạng có hàng trăm lớp.
- **Kiến trúc decoder-only/Transformer hiện đại:** thường dùng Pre-Layer-Norm (chuẩn hoá trước mỗi khối, không phải sau) kết hợp He/Xavier-như initialization đã điều chỉnh theo độ sâu (vd. scale theo $1/\sqrt{2L}$ với L là số lớp) — một sự tổng hợp trực tiếp của cả ba ý tưởng: initialization đúng, chuẩn hoá liên tục, và đường

tắt gradient.

Ba kỹ thuật trên nằm ngoài phạm vi thực nghiệm của báo cáo (kiến trúc cố định là MLP thuần, không residual/normalization — Mục 7), nhưng thực nghiệm độ sâu (Mục 6.1, đặc biệt điểm gây tại $L=12$ của He) minh họa trực tiếp *tại sao* các kỹ thuật này trở thành tiêu chuẩn bắt buộc trong mọi kiến trúc sâu hiện đại thay vì chỉ dựa vào initialization.

10.4 Câu hỏi thường gặp

“Nếu dùng Adam thay vì SGD thì kết quả Sigmoid có khá hơn không?” Có thể một phần — Adam (Mục 4.6) tự động tăng bước cập nhật cho tham số có gradient lịch sử nhỏ, nên có thể bù một phần cho gradient nhỏ (nhưng khác 0) của Sigmoid+He. Tuy nhiên với Zero-init, gradient đúng bằng 0 nên Adam cũng không giúp được gì (đã giải thích ở hộp trực giác Mục 4.6). Báo cáo không kiểm chứng thực nghiệm giả thuyết này (cố định SGD thuần để giữ fair experiment, Mục 11).

“Kết quả có đổi nhiều không nếu dùng activation khác cho lớp output?” Không — lớp output trong mọi thực nghiệm của báo cáo luôn là linear (logits thô), như mô tả ở Mục 3, 7. Đây là lựa chọn chuẩn cho bài toán phân loại nhiều lớp dùng CrossEntropyLoss (hàm loss tự áp dụng softmax bên trong), không liên quan tới initialization của các lớp ẩn đang khảo sát.

“Tại sao không thử nhiều seed để có khoảng tin cậy?” Đây chính là hạn chế lớn nhất đã nêu ở Mục 11 — một seed duy nhất mỗi cấu hình là đủ để minh họa *xu hướng* (chênh lệch lớn giữa Zero/Random và LeCun/Xavier/He rõ ràng vượt xa nhiễu ngẫu nhiên), nhưng không đủ để so sánh *định lượng chính xác* giữa các scheme gần nhau (vd. He vs. Xavier cho ReLU).

11 Hạn chế

Các hạn chế dưới đây phần lớn là **lựa chọn có chủ đích** để giữ thực nghiệm gọn, chạy nhanh trên CPU và giữ đúng nguyên tắc fair experiment (Mục 7), không phải sai sót. Mục đích liệt kê rõ ràng ở đây là để người đọc biết chính xác *phạm vi* mà các kết luận của báo cáo (Mục 9–10) có thể áp dụng, và phạm vi nào cần thêm thực nghiệm mới có thể khẳng định.

- **Quy mô nhỏ:** subset 5 000/1 000/2 000 mẫu, 15 epoch, để chạy nhanh trên CPU — không phản ánh kết quả ở quy mô full Fashion-MNIST hay nhiều epoch hơn (đặc biệt với Sigmoid, có thể cần rất nhiều epoch hơn để vượt qua giai đoạn gradient nhỏ ban đầu).
- **Một seed duy nhất** mỗi cấu hình — không đo được variance giữa nhiều lần chạy độc lập, nên các chênh lệch nhỏ (vd. He vs. Xavier trên ReLU, Mục 10) không thể khẳng định có ý nghĩa thống kê.
- **SGD thuần, không tinh chỉnh LR riêng** cho từng cấu hình (cố ý, để giữ fair experiment) — nghĩa là một số cấu hình (vd. Sigmoid) có thể học nhanh hơn nếu được tinh chỉnh LR riêng; kết luận “Sigmoid thất bại” cần hiểu trong đúng phạm vi thiết lập này.
- **Không BatchNorm/Dropout/LR schedule** — cố ý loại bỏ để initialization là biến duy nhất, nhưng vì vậy kết quả không đại diện cho thiết lập huấn luyện hiện đại (nơi BatchNorm thường giảm đáng kể độ nhạy với initialization).

- **Validation dao động mạnh** (Hình 11) do tập val nhỏ (1 000 mẫu) — nên đọc xu hướng chung thay vì giá trị từng epoch riêng lẻ.
- **Lớp output cũng khởi tạo theo cùng scheme** với các lớp ẩn (xem `src/models.py`) dù lớp output không có activation phi tuyến phía sau — lựa chọn đơn giản hoá, có thể không tối ưu tuyệt đối nhưng không ảnh hưởng tới các kết luận định tính của báo cáo.
- **Thực nghiệm độ sâu** (Mục 6.1) dùng 8 epoch (ít hơn 15 epoch của lưới chính) và cũng chỉ 1 seed — điểm gãy tại $L=12$ của He (Hình 5) là một quan sát thật nhưng *đơn lẻ*; chưa đủ để khẳng định đây là quy luật chung hay đặc thù của đúng seed/kiến trúc này. Cần chạy nhiều seed ở các độ sâu lân cận ($L=11, 13$) để xác nhận trước khi coi đây là kết luận tổng quát.

Tổng hợp lại: giới hạn lớn nhất xuyên suốt là **thiếu lặp lại nhiều seed** — mọi so sánh *định tính* của báo cáo (Zero/Random thất bại tuyệt đối, Sigmoid thất bại với mọi scheme, LeCun/Xavier/He thành công rõ rệt với Tanh/ReLU) đều đủ chắc chắn vì chênh lệch rất lớn so với nhiễu ngẫu nhiên hợp lý của một seed; nhưng mọi so sánh *định lượng chính xác* giữa các cấu hình gần nhau (He vs. Xavier, điểm gãy độ sâu chính xác của He) cần thêm thực nghiệm nhiều seed mới nên trích dẫn như số liệu dứt khoát.

12 Kết luận

Báo cáo trình bày Backpropagation như hệ quả trực tiếp của Chain Rule áp dụng có hệ thống trên một computational graph (Mục 2.5–4), phân biệt rõ với Gradient Descent (Mục 4.5): Backprop *tính* gradient, Gradient Descent *dùng* gradient đó để cập nhật tham số. Về Initialization, báo cáo chứng minh bằng cả suy luận toán học (Mục 5) lẫn thực nghiệm thật (Mục 9) rằng lựa chọn θ_0 ảnh hưởng quyết định tới việc mạng có học được hay không: Zero-init xoá hoàn toàn khả năng phá vỡ đối xứng (gradient lớp ẩn $\equiv 0$, đo được chính xác bằng 0,0 trong thực nghiệm); Random (naive) và ngay cả He/Xavier với activation bão hoà sâu (Sigmoid, 6 lớp) vẫn có thể vanishing đủ mạnh để chặn đứng việc học trong thời gian huấn luyện ngắn. Hai chủ đề tưởng như tách biệt của báo cáo hoá ra là hai mặt của cùng một câu hỏi: *làm sao gradient “chảy” xuyên suốt một mạng nhiều lớp mà không biến mất hay bùng nổ* — Backpropagation là cơ chế *tính* dòng chảy đó, Initialization là điều kiện *ban đầu* quyết định dòng chảy đó có sống sót qua nhiều lớp hay không.

Đóng góp cụ thể của báo cáo (tổng hợp lại các mục thực nghiệm): (1) triển khai và kiểm chứng Backpropagation thủ công bằng NumPy, khớp tuyệt đối PyTorch autograd và finite-difference tới sai số 10^{-9} (Mục 8.3); (2) lưới thực nghiệm đầy đủ $5 \times 4 = 20$ cấu hình initialization $\times$ activation trên Fashion-MNIST, xác nhận trực tiếp các dự đoán lý thuyết bằng số liệu đo được, không suy diễn (Mục 9); (3) thực nghiệm bổ sung về độ sâu mạng (Mục 6.1), cho thấy cả hiện tượng vanishing kinh điển (Random, suy giảm 12 bậc độ lớn qua 12 lớp) lẫn một giới hạn ít được nhắc tới của chính He initialization ở độ sâu rất lớn.

Hướng mở rộng nếu có thêm thời gian/tài nguyên (liệt kê đầy đủ ở Mục 11): lặp lại lưới thực nghiệm với nhiều seed để có khoảng tin cậy; thêm Batch Normalization như một biến thực nghiệm thứ ba để đo trực tiếp mức độ nó làm giảm độ nhạy với initialization (dự đoán ở Mục 10 nhưng chưa kiểm chứng thực nghiệm); mở rộng thực nghiệm độ sâu (Mục 6.1) sang kiến trúc có residual connection để so sánh trực tiếp với MLP thuần.

Tài liệu tham khảo

- Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- Xavier Glorot and Yoshua Bengio. Understanding the difficulty of training deep feedforward neural networks. In *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS)*, volume 9, pages 249–256. PMLR, 2010.
- Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2015. arXiv:1502.01852.
- Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015. arXiv:1412.6980.
- Yann LeCun, Léon Bottou, Genevieve B. Orr, and Klaus-Robert Müller. Efficient backprop. In *Neural Networks: Tricks of the Trade*, volume 7700 of *Lecture Notes in Computer Science*. Springer, 2nd edition, 2012. Bản gốc xuất bản trong LNCS vol. 1524, 1998.
- Adam Paszke et al. Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. arXiv:1912.01703.
- David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323:533–536, 1986.
- Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-MNIST: a novel image dataset for benchmarking machine learning algorithms, 2017. arXiv:1708.07747.

A Mã nguồn Manual Backpropagation

Hai đoạn code cốt lõi của Part A (Mục 8), trích nguyên văn từ `src/manual_nn.py` và `src/initialization.py` — toàn bộ báo cáo, notebook và slide đều gọi trực tiếp các hàm này, không có bản sao chỉnh sửa riêng cho việc trình bày.

Listing 4: Forward pass – `src/manual_nn.py`

```
def forward(self, X: np.ndarray) -> np.ndarray:
    """X: (N, n0). Tra ve Yhat: (N, nL). Lop cuoi (output) LUON linear
    (khong qua self.f) -- khop quy uoc dung trong models.py va Phase 2."""
    A = X
    Zs, As = [], [A]
    for l in range(self.n_layers):
        Z = A @ self.W[l] + self.b[l]
        is_last = l == self.n_layers - 1
        A = Z if is_last else self.f(Z)
        Zs.append(Z)
        As.append(A)
    self._cache = {"Zs": Zs, "As": As}
    return A
```

Listing 5: Backward pass – `src/manual_nn.py` (nguyên văn công thức Mục 4.3)

```
def backward(self, Yhat: np.ndarray, Y: np.ndarray) -> dict:
    """Tinh dL/dW[l], dL/db[l] cho moi lop bang chain rule:
    dZ^(l) = dA^(l) o f'(Z^(l))      (o = Hadamard)
    dW^(l) = (A^(l-1))^T dZ^(l)
```

```

        db^(l) = 1^T dZ^(l)                (tong theo truc batch)
        dA^(l-1) = dZ^(l) (W^(l))^T
    Loss: MSE trung binh batch -> dL/dYhat = (Yhat - Y) / N.
    """
    Zs, As = self._cache["Zs"], self._cache["As"]
    N = Y.shape[0]
    grads_W = [None] * self.n_layers
    grads_b = [None] * self.n_layers

    dA = (Yhat - Y) / N # dL/dA^(L), L = output layer (linear)
    for l in reversed(range(self.n_layers)):
        is_last = l == self.n_layers - 1
        dZ = dA if is_last else dA * self.f_grad(Zs[l])
        A_prev = As[l] # As[l] = A^(l-1) vi As[0]=X
        grads_W[l] = A_prev.T @ dZ
        grads_b[l] = dZ.sum(axis=0)
        dA = dZ @ self.W[l].T # dL/dA^(l-1), dung cho vong lap ke tiep
    return {"dW": grads_W, "db": grads_b}

```

Listing 6: Công thức Var(W) cho tung scheme – src/initialization.py (nguyên văn Bảng 5)

```

def weight_variance(scheme, fan_in, fan_out):
    if scheme == "zero":
        return 0.0
    if scheme == "random_normal":
        return 0.01 ** 2 # sigma co dinh, KHONG scale theo fan_in
    if scheme == "lecun":
        return 1.0 / fan_in
    if scheme == "xavier":
        return 2.0 / (fan_in + fan_out)
    if scheme == "he":
        return 2.0 / fan_in
    raise KeyError(f"Khong biet scheme '{scheme}'")

```

B Bảng kết quả đầy đủ (20 cấu hình)

Bảng 14 liệt kê đầy đủ 4 metric (không chỉ test accuracy như Bảng 13 Mục 9) cho toàn bộ 20 cấu hình, lấy trực tiếp từ results/tables/initialization_comparison.csv.

Bảng 14: Kết quả đầy đủ: train/val/test loss và test accuracy, 20 cấu hình

Scheme	Activation	Train loss	Val loss	Test loss	Test acc.
Zero	Sigmoid	2,309	2,315	2,314	0,100
Zero	Tanh	2,303	2,303	2,303	0,100
Zero	ReLU	2,303	2,303	2,303	0,100
Zero	Leaky ReLU	2,303	2,303	2,303	0,100
Random	Sigmoid	2,309	2,315	2,313	0,100
Random	Tanh	2,303	2,303	2,303	0,100
Random	ReLU	2,303	2,303	2,303	0,100
Random	Leaky ReLU	2,303	2,303	2,303	0,100
LeCun	Sigmoid	2,309	2,317	2,315	0,100
LeCun	Tanh	0,349	1,116	1,098	0,689
LeCun	ReLU	0,390	1,808	1,742	0,638
LeCun	Leaky ReLU	0,385	1,807	1,732	0,648
Xavier	Sigmoid	2,310	2,318	2,317	0,100
Xavier	Tanh	0,310	1,246	1,239	0,692
Xavier	ReLU	0,378	1,423	1,373	0,674
Xavier	Leaky ReLU	0,373	1,482	1,410	0,682
He	Sigmoid	2,310	2,319	2,317	0,100
He	Tanh	0,223	1,337	1,329	0,694
He	ReLU	0,256	1,919	1,822	0,667
He	Leaky ReLU	0,258	2,691	2,579	0,634

Đọc bảng: cột in đậm là giá trị cao nhất theo cột trong nhóm Tanh/ReLU/Leaky ReLU (Sigmoid không có cột in đậm vì cả 5 scheme đều 0,100 — không có “người thắng”, xem thảo luận Mục 10). Chênh lệch train loss vs. val/test loss ở mọi cấu hình học được (vd. He+Tanh: 0,223 so với 1,337) phản ánh đúng hiện tượng overfitting nhẹ đã nêu ở Mục 9.7 — dự kiến với 5 000 mẫu train, không regularization, 15 epoch.

C 20 câu hỏi phản biện thường gặp

Tổng hợp ngắn gọn, dùng để chuẩn bị hỏi–đáp khi bảo vệ báo cáo; mỗi câu trả lời có trích dẫn mục tương ứng để tra cứu chi tiết.

1. **Backpropagation là gì?** Thuật toán tính $\nabla_{\theta}L$ hiệu quả bằng Chain Rule áp dụng có hệ thống trên computational graph, tận dụng giá trị đã lưu từ forward pass (Mục 4).
2. **Vì sao cần Chain Rule?** Vì L là hợp của nhiều phép biến đổi lồng nhau qua các lớp; Chain Rule là quy tắc toán học duy nhất cho phép tính đạo hàm của một hàm hợp mà không cần khai triển tường minh toàn bộ biểu thức (Mục 2.5).
3. **Backpropagation khác Gradient Descent như thế nào?** Backprop *tính* gradient; Gradient Descent *dùng* gradient đó để cập nhật tham số ($\theta \leftarrow \theta - \eta \nabla_{\theta}L$) — hai vai trò tách biệt, không thể hoán đổi (Mục 4.5).

4. **Tại sao gradient có thể vanish?** Gradient qua L lớp xấp xỉ g^L với g = độ lớn trung bình mỗi đạo hàm cục bộ; nếu $g < 1$ (activation bão hoà và/hoặc weight scale nhỏ), $g^L \rightarrow 0$ theo hàm mũ khi L tăng (Mục 6).
5. **Tại sao gradient có thể explode?** Cùng cơ chế trên nhưng $g > 1$ (weight scale quá lớn) khiến $g^L \rightarrow \infty$ theo hàm mũ (Mục 6).
6. **Tại sao initialize toàn bộ weight = 0 không tốt?** Mọi neuron trong một lớp nhận cùng input, cùng trọng số $\Rightarrow$ cùng gradient $\Rightarrow$ mãi mãi giống hệt nhau (mất symmetry breaking); nếu $W=0$ ở mọi lớp, gradient lớp ẩn còn bằng *đúng* 0, do được thực nghiệm (Mục 5.2).
7. **Tại sao phải randomize parameter?** Để phá vỡ đối xứng giữa các neuron trong cùng lớp — điều kiện *cần* nhưng chưa *đủ* (còn phải scale đúng theo n_{in} , xem câu 8–10) (Mục 5.3).
8. **Xavier giải quyết vấn đề gì?** Chọn $\text{Var}(W) = 2/(n_{in} + n_{out})$ để dung hoà đồng thời điều kiện giữ ổn định variance khi forward ($1/n_{in}$) và khi backward ($1/n_{out}$), phù hợp activation đối xứng (Tanh/Sigmoid) (Mục 5.5).
9. **He initialization khác Xavier thế nào?** He dùng $\text{Var}(W) = 2/n_{in}$ — gấp đôi Xavier (khi $n_{in}=n_{out}$) để bù việc ReLU triệt tiêu khoảng một nửa variance tín hiệu (phần $z < 0 \rightarrow 0$) (Mục 5.5).
10. **Tại sao ReLU thường đi với He initialization?** Vì He được suy ra *trực tiếp* từ đặc tính của ReLU (hệ số bù $\times 2$ ở câu 9); dùng Xavier cho ReLU vẫn hoạt động (Bảng 13: Xavier+ReLU 67,4%) nhưng không xuất phát từ đúng giả định về activation (Mục 5.5, 10).
11. **fan_in và fan_out là gì?** $\text{fan_in} = n_{l-1}$ (số input của 1 neuron), $\text{fan_out} = n_l$ (số neuron lớp sau nhận input từ neuron này) — hai đại lượng quyết định $\text{Var}(z) = n_{in}\text{Var}(W)\text{Var}(x)$ (Mục 5.5).
12. **Initialization ảnh hưởng activation variance như thế nào?** $\text{Var}(a^{(l)}) \approx r^l \text{Var}(x)$ với $r = n_{in}\text{Var}(W)$ (đã hiệu chỉnh activation) — xem ví dụ số Bảng 6 và số liệu đo thật Hình 9 (Mục 5.7, 9).
13. **Initialization ảnh hưởng gradient variance như thế nào?** Cùng cơ chế nhân dồn theo chiều ngược lại (thay n_{in} bằng n_{out} trong phân tích) — đo thực tế ở Hình 8 (Mục 6, 9).
14. **Tại sao network càng sâu càng nhạy với initialization?** Vì hệ số r (hoặc g) bị nhân dồn theo *luỹ thừa của số lớp* — một sai lệch nhỏ ở r so với 1 bị khuếch đại theo hàm mũ của độ sâu, chứng minh trực tiếp bằng thực nghiệm độ sâu (Hình 5, Mục 6.1).
15. **PyTorch autograd thực hiện điều gì?** Tự động xây và duyệt ngược computational graph để tính gradient — về bản chất toán học cũng là Backpropagation, chỉ tự động hoá việc xây đồ thị thay vì viết tay (Mục 8).
16. **Manual gradient và autograd khác nhau như thế nào?** Không khác về kết quả (Mục 8.3: sai số $\approx 10^{-9}$, chỉ là sai số làm tròn) — chỉ khác về việc *ai* xây computational graph và tính đạo hàm cục bộ: người viết code (manual) hay framework (autograd).
17. **Gradient checking dùng để làm gì?** Đối chiếu gradient tính bằng backprop với gradient tính bằng finite-difference (chậm nhưng đáng tin) để *cô lập lỗi* khi tự viết backward pass thủ công (Mục 8.3).
18. **Có phải initialization tốt luôn đảm bảo model tốt không?** Không — là điều kiện *cần*, không phải *đủ*. Thực nghiệm Sigmoid (Mục 10) và thực nghiệm độ sâu

$L=12$ (Mục 6.1) đều cho thấy initialization đúng lý thuyết vẫn có thể thất bại nếu thiếu thêm điều kiện khác (đủ epoch, learning rate phù hợp, hoặc kỹ thuật ổn định bổ sung).

19. **Initialization có còn quan trọng khi dùng BatchNorm/LayerNorm không?** Có, nhưng *ít nhạy cảm hơn nhiều* — Batch/Layer Norm chuẩn hoá lại phân phối tín hiệu sau *mỗi* lớp trong suốt huấn luyện, không chỉ dựa vào việc chọn đúng $\text{Var}(W)$ một lần lúc khởi tạo (Mục 10).
20. **Initialization và optimizer có quan hệ như thế nào?** Độc lập về vai trò (Mục 4.5) nhưng phối hợp trong thực tế: optimizer thích ứng (Adam) có thể bù *một phần* gradient nhỏ do initialization dưới mức tối ưu, nhưng không cứu được trường hợp gradient bằng đúng 0 (Zero-init) — hộp trực giác Mục 4.6.

D Danh mục notebook

Ngoài script trong `experiments/`, project kèm 5 Jupyter notebook (`notebooks/01–05`, đã chạy sẵn với output thật, không cần chạy lại để xem kết quả) — mỗi notebook tương ứng một mục của báo cáo, dùng khi cần trình bày tương tác thay vì đọc PDF tĩnh:

Notebook	Nội dung	Mục liên quan
01_derivative_demo	Đạo hàm là độ nhạy ($y = x^2$, tiếp tuyến); Chain Rule trên ví dụ $x \rightarrow z \rightarrow a \rightarrow L$	Mục 2.5
02_manual_backprop	Chạy ManualMLP trên đúng ví dụ 2 lớp của báo cáo; đối chiếu PyTorch autograd trực tiếp trong notebook	Mục 4.2
03_gradient_check	Chạy lại <code>run_gradient_check.py</code> , hiển thị report JSON đầy đủ	Mục 8.3
04_initialization_experiment	Nạp lại <code>results/</code> (không chạy lại 20 cấu hình), hiển thị bảng + 4 hình chính	Mục 9
05_analysis	Bảng pivot test accuracy đầy đủ + 3 quan sát chính, dùng cùng logic phân tích với Mục 10	Mục 10

E Bảng thuật ngữ Việt–Anh

Đạo hàm — <i>Derivative</i>	Lan truyền tiến — <i>Forward Propagation</i>	Khởi tạo tham số — <i>Parameter Initialization</i>
Đạo hàm riêng — <i>Partial Derivative</i>	Lan truyền ngược — <i>Back-propagation</i>	Phá vỡ đối xứng — <i>Symmetry Breaking</i>
Gradient	Đồ thị tính toán — <i>Computational Graph</i>	Gradient biến mất — <i>Vanishing Gradient</i>
Ma trận Jacobian — <i>Jacobian</i>	Hàm kích hoạt — <i>Activation Function</i>	Gradient bùng nổ — <i>Exploding Gradient</i>
Quy tắc chuỗi — <i>Chain Rule</i>	Hàm mất mát — <i>Loss Function</i>	Chuẩn hoá theo lô — <i>Batch Normalization</i>
Trọng số dùng chung — <i>Weight Sharing</i>	Nhân từng phần tử — <i>Hadamard Product</i>	Kết nối tắt — <i>Residual/Skip Connection</i>
Lô (dữ liệu) — <i>Batch</i>	Suy giảm trọng số — <i>Weight Decay</i>	Học sâu — <i>Deep Learning</i>
Siêu tham số — <i>Hyperparameter</i>	Quá khớp — <i>Overfitting</i>	Kiểm tra gradient — <i>Gradient Checking</i>

Bảng 15: Đối chiếu thuật ngữ tiếng Việt – tiếng Anh dùng trong báo cáo